

硕士学位论文

(专业学位论文)

基于结构与语义分析的大语言模型检索增强
生成方法

**LARGE LANGUAGE MODEL
RETRIEVAL-AUGMENTED
GENERATION METHODS BASED ON
STRUCTURAL AND SEMANTIC
ANALYSIS**

李士朋

哈尔滨工业大学

2026 年 6 月

国内图书分类号：TP391.1

国际图书分类号：004.8

学校代码：10213

密级：公开

硕士学位论文

基于结构与语义分析的大语言模型检索增强 生成方法

硕士研究生：李士朋

导 师：汤步洲教授

申 请 学 位：专业学位硕士

类 别：电子信息

所 在 单 位：哈尔滨工业大学（深圳）

答 辩 日 期：2026 年 5 月

授予学位单位：哈尔滨工业大学

Classified Index: TP391.1

U.D.C: 004.8

Dissertation for the Master Degree

**LARGE LANGUAGE MODEL
RETRIEVAL-AUGMENTED
GENERATION METHODS BASED ON
STRUCTURAL AND SEMANTIC
ANALYSIS**

Candidate:	Shipeng Li
Supervisor:	Prof. Buzhou Tang
Academic Degree Applied for:	Professional Master's Degree
Specialty:	Electronic and Information Engineering
Affiliation:	Harbin Institute of Technology, Shenzhen
Date of Defense:	May, 2026
Degree-Confering-Institution:	Harbin Institute of Technology

摘要

随着大语言模型 (Large Language Models, LLMs) 的快速发展, 其在自然语言处理等多个领域中表现出良好的性能。然而, 由于蕴含在模型参数中知识的静态性, LLMs 容易因知识过时而产生“幻觉”现象。检索增强生成 (Retrieval-Augmented Generation, RAG) 通过引入外部知识增强了 LLMs 生成结果的事实性与可靠性, 但现有的 RAG 方法在知识密集型多跳推理任务等复杂场景下仍存在上下文噪声较大、语义表达能力不足以及推理能力有限等问题。针对上述问题, 本文围绕“结构分析”与“语义分析”两个方向展开研究, 提出了两种改进方法。

针对复杂多跳问答任务中上下文信噪比较低的问题, 提出了一种基于结构分析的检索增强生成方法。通过从检索文档中抽取短语结构三元组, 构建结构化推理路径, 并基于推理路径精确索引相关文本, 构建“结构引导 + 文本补充”的增强上下文表示, 以提高知识密度, 降低上下文噪声。在三个典型多跳问答数据集 MuSiQue、2WikiMultiHopQA 和 HotpotQA 上的实验结果表明, 所提出的方法在各项指标上均优于对比方法。其中, 在 2WikiMultiHopQA 数据集上, EM 和 F1 分别达到 55.20% 和 65.09%, 相较次优方法分别提升 2.80% 和 3.76%。在所有数据集上的平均性能达到 55.20%, 取得最优整体表现。同时, 在保证性能的前提下, 所提出的方法将平均输入 Token 长度减少约 70%–80%, 显著提升了推理效率与结果可解释性。

针对基于图结构的 RAG 方法依赖复杂关系建模且构建成本较高的问题, 提出了一种基于结构与语义联合建模的检索增强生成方法。在短语结构三元组和文本片段的基础上, 引入实体语义信息抽取, 并提出基于句子加权的段落表示方法, 构建“结构 + 文本 + 语义”联合增强上下文, 提升上下文的信息密度与表达能力。在 MuSiQue、2WikiMultiHopQA 和 HotpotQA 数据集上进行实验, 所提出的方法的包含匹配准确率 (Contain-Acc.) 和大语言模型评估准确率 (GPT-Acc.) 分别达到 58.57% 和 57.93%, 在整体性能上优于多种基准方法。所提出的方法在保持较低检索成本的同时, 有效提升了大语言模型的推理能力与生成性能。

关键词: 检索增强生成; 大语言模型; 结构化推理; 联合语义建模

Abstract

With the rapid development of Large Language Models (LLMs), they have demonstrated strong performance in many fields such as natural language processing. However, due to the static nature of knowledge stored in model parameters, LLMs are prone to generating hallucinations caused by outdated knowledge. Retrieval-Augmented Generation (RAG) enhances the factuality and reliability of LLM-generated results by introducing external knowledge. Nevertheless, existing RAG methods still suffer from issues such as excessive contextual noise, insufficient semantic representation capability, and limited reasoning ability in complex scenarios including knowledge-intensive multi-hop reasoning tasks. To address these challenges, this thesis conducts research from two perspectives: structural analysis and semantic analysis, and proposes two improved methods.

To address the low signal-to-noise ratio of context in complex multi-hop question answering tasks, this thesis proposes a retrieval-augmented generation method based on structural analysis. By extracting phrase-structured triples from retrieved documents, the method constructs structured reasoning paths and accurately indexes relevant texts based on these reasoning paths. A “structure-guided + text-supplemented” enhanced context representation is then constructed to improve knowledge density and reduce contextual noise. Experimental results on three representative multi-hop question answering benchmarks, namely MuSiQue, 2WikiMultiHopQA, and HotpotQA, demonstrate that the proposed method consistently outperforms competing approaches across all evaluation metrics. Specifically, on the 2WikiMultiHopQA dataset, the proposed method achieves an EM score of 55.20% and an F1 score of 65.09%, surpassing the second-best method by 2.80% and 3.76%, respectively. The proposed method achieves an average overall performance of 55.20% across all datasets, obtaining the best comprehensive performance. Meanwhile, while maintaining strong performance, the proposed method reduces the average input token length by approximately 70%–80%, significantly improving reasoning efficiency and result interpretability.

To address the high construction cost and complex relational modeling dependency of graph-based RAG methods, this thesis further proposes a retrieval-augmented generation method based on joint structural and semantic modeling. Built upon phrase-structured triples and text passages, the method further introduces entity-level semantic information extraction and proposes a sentence-weighted paragraph representation approach. A jointly

enhanced context integrating “structure + text + semantics” is then constructed to improve context knowledge density and semantic representation capability. Experimental results on MuSiQue, 2WikiMultiHopQA, and HotpotQA show that the proposed method achieves a Containment Matching Accuracy (Contain-Acc.) of 58.57% and a Large Language Model-based Evaluation Accuracy (GPT-Acc.) of 57.93%, outperforming multiple baseline methods in overall performance. While maintaining relatively low retrieval cost, the proposed method effectively improves the reasoning ability and generation performance of large language models.

Keywords: Retrieval-Augmented Generation, Large Language Models, Structured Reasoning, Joint Semantic Modeling

目 录

摘 要	I
ABSTRACT	II
第 1 章 绪 论	1
1.1 课题背景及研究的目的和意义	1
1.1.1 课题背景	1
1.1.2 研究目的与意义	2
1.2 国内外研究现状	3
1.2.1 基于外部文档的检索增强生成	3
1.2.2 基于公开知识图谱的检索增强生成	4
1.2.3 基于开放式信息抽取的检索增强生成	5
1.3 本文的主要研究内容	7
1.4 本文组织结构	8
第 2 章 相关研究概述	10
2.1 引言	10
2.2 检索增强生成技术	10
2.2.1 朴素检索增强生成	10
2.2.2 基于知识图谱的检索增强生成	12
2.3 文本表示与向量检索技术	15
2.4 知识图谱构建技术	17
2.4.1 命名实体识别技术	17
2.4.2 开放式信息抽取技术	18
2.5 本章小结	20
第 3 章 基于结构分析的检索增强生成方法	21
3.1 引言	21
3.2 短语结构三元组图构建	23
3.2.1 短语结构三元组图表示	23
3.2.2 短语结构三元组抽取	24
3.2.3 短语结构三元组图构建	25
3.3 基于短语结构三元组的结构化推理路径构建	25
3.3.1 短语结构三元组表示与编码	26

3.3.2 迭代式路径扩展	26
3.3.3 基于大语言模型的短语结构三元组选择	27
3.3.4 基于束搜索的并行路径扩展	28
3.3.5 路径终止与推理路径生成	28
3.4 基于结构化推理路径的上下文证据索引	29
3.4.1 文本证据索引	29
3.4.2 证据链编排	29
3.4.3 最终答案生成	31
3.5 实验结果与分析	31
3.5.1 数据集	31
3.5.2 实验设置与评价指标	32
3.5.3 基线模型	33
3.5.4 性能实验结果与分析	34
3.5.5 消融实验结果与分析	36
3.5.6 样例分析	38
3.6 本章小结	40
第 4 章 基于结构与语义联合建模的检索增强生成方法	42
4.1 引言	42
4.2 语义信息抽取	44
4.2.1 短语结构三元组抽取	45
4.2.2 实体语义信息抽取	45
4.2.3 联合结构与语义信息组织	46
4.3 基于句子加权的段落表示方法	46
4.3.1 句子级语义表示	46
4.3.2 句子权重建模	47
4.3.3 段落表示构建	47
4.4 结构增强的联合语义上下文构建方法	47
4.4.1 结构与语义信息检索	48
4.4.2 结构增强的联合上下文构建	49
4.5 实验结果及分析	50
4.5.1 数据集	50
4.5.2 实验设置及评价指标	50
4.5.3 基线模型	51
4.5.4 性能实验结果及分析	51
4.5.5 消融实验结果及分析	56
4.5.6 样例分析	58
4.6 本章小结	59

结 论	60
参考文献	61
攻读硕士学位期间取得创新性成果	67
哈尔滨工业大学学位论文原创性声明和使用权限	68
致 谢	69

第 1 章 绪 论

1.1 课题背景及研究的目的和意义

1.1.1 课题背景

近年来,随着深度学习技术的快速发展,以大语言模型(Large Language Models, LLMs)为代表的生成式人工智能取得了突破性进展。尤其是自 OpenAI 于 2022 年发布 ChatGPT 以来,人工智能研究进入了以大规模预训练模型为核心的新阶段^[1]。LLMs 凭借其强大的语义理解能力与文本生成能力,在自然语言处理等多个领域中展现出优异的性能^[2-4]。与传统任务驱动模型不同,通用大语言模型通过在海量跨领域语料上进行预训练,具备较强的跨任务迁移能力,为通用人工智能的发展提供了重要基础。

然而,随着研究的不断深入,LLMs 的局限性也逐渐显现。首先,通用大语言模型虽然具备良好的泛化能力,但在特定领域任务中往往难以超越专用模型,导致在实际应用中仍需针对具体场景进行定制化优化。其次,LLMs 的知识主要来源于预训练阶段所使用的数据,其知识具有明显的“静态性”,难以及时反映现实世界中的动态变化。当面对需要最新信息或精确知识的任务时,模型容易产生过时或错误的回答。此外,在医疗等对数据安全性要求较高的领域,受限于可用训练数据,LLMs 的表现往往受到进一步制约^[5]。

在知识密集型任务(Knowledge-Intensive Tasks)中,尤其是涉及多跳推理的问答任务,LLMs 的上述问题更加突出。模型在处理超出训练数据范围或需要跨文档推理的问题时,容易产生“幻觉”现象,即生成与事实不符的内容^[6-8]。为了解决这一问题,检索增强生成(Retrieval-Augmented Generation, RAG)方法被提出,如图1-1所示,相比于直接将用户问题输入进行 LLMs 生成,RAG 方式通过从外部知识库动态检索相关信息,并将其作为上下文输入模型,能够提示模型利用最新、相关的知识进行推理与生成,从而增强生成结果的事实性与可靠性^[9-11]。

近年来,RAG 已成为提升 LLMs 性能的重要技术路径,并在多个研究工作中得到广泛应用。然而,现有 RAG 方法在面对大规模非结构化语料时仍面临显著挑战。由于相关信息通常分散在多个异构文档中,检索得到的上下文往往规模庞大且缺乏结构组织,导致噪声信息大量引入,从而影响模型的推理准确性与生成连贯性^[12-14]。尽管部分研究通过将文档划分为更细粒度的片段以提升检索效率^[15,16],但该策略容易破坏原有语义结构,导致关键上下文信息丢失,从而降低复杂推理任务的性能^[17,18]。




图 1-1 LLMs 直接生成和 RAG 方法对比图

为缓解上述问题，研究人员进一步尝试将结构化知识引入 RAG 框架中，其中知识图谱（Knowledge Graph, KG）^[19] 被广泛用于建模实体及其关系，以提升多跳推理能力。这类方法通过显式建模结构化知识，在一定程度上提高了检索的相关性与推理的可解释性。然而，由于知识图谱通常依赖自动化关系抽取构建，其质量容易受到噪声与错误传播的影响，进而影响整体性能。

因此，如何在降低上下文噪声的同时提升结构分析能力、语义表达能力与推理能力，成为当前检索增强生成研究中的关键问题。围绕这一问题，本文从“结构分析”与“语义分析”两个角度出发，探索高效的检索增强生成方法。

1.1.2 研究目的与意义

针对当前大语言模型在知识密集型多跳问答任务中存在的知识静态性、推理能力不足以及检索增强生成方法中上下文噪声较大等问题，本文旨在探索更加高效的检索增强生成方法，以提升模型在复杂推理场景中的表现能力。

具体而言，本文从“结构分析”与“语义分析”两个角度出发，研究如何在引入外部知识的同时，更加高效地组织、分析与表达检索到的上下文信息。一方面，通过构建显式的结构化推理路径，引导模型逐步完成多跳推理过程，以减少无关信息干扰并增强结构分析能力；另一方面，通过引入结构与语义联合建模机制，提升检索信息的表达能力与利用效率，从而在无需大规模模型训练的前提下，增强大语言模型的推理性能与泛化能力。

本文的研究工作具有以下几个方面的重要意义：

(1) **提升多跳问答任务的推理能力：**通过引入结构分析与结构语义联合建模机制，有效缓解传统 RAG 方法在复杂推理任务中的能力不足问题，提升模型对跨文档、多步推理问题的处理能力。

(2) **降低上下文噪声并提高信息利用效率：**针对检索结果中存在的冗余与噪声问题，本文通过结构分析与结构语义联合建模相结合的方式，提高上下文信息的信噪比与知识密度，从而提升模型生成结果的准确性与稳定性。

(3) **提高方法的可解释性与可扩展性：**显式结构化推理过程能够清晰展示模型的推理路径，而结构与语义联合建模则增强了上下文表达能力与灵活性。两类方法分别从不同角度提升模型性能，不仅增强了结果的可解释性，也为不同场景下的方法扩展提供了更强的适应能力。

(4) **降低应用成本并增强实际可用性：**相比于重新训练领域专用大模型，本文方法通过改进检索、结构分析与上下文构建策略，在保持较低计算成本的同时实现性能提升，为大语言模型在实际复杂任务场景中的落地应用提供了更加可行的解决方案。

综上所述，本文的研究不仅在方法层面上对检索增强生成技术进行了系统探索，也在实际应用层面为提升大语言模型在复杂多跳推理任务中的性能、效率与可解释性提供了新的研究思路。

1.2 国内外研究现状

1.2.1 基于外部文档的检索增强生成

基于外部文档的检索增强生成方法主要面向非结构化文本语料，通过检索器从外部语料库中选取与查询最相关的若干文档片段，并将其直接拼接到输入上下文中，以辅助大语言模型生成答案。该类方法通常不显式构建图结构，也不额外设计结构化推理路径，而是依赖语义相似度检索与生成模型自身的上下文理解能力完成问答，因此具有实现简单、易于扩展和适配现有大语言模型的优点。

从发展脉络上看，REALM (Retrieval-Augmented Language Model)^[20] 较早将“可检索的外部知识存储”引入语言模型预训练过程，证明了通过外部文档检索增强语言模型能够有效提升开放域问答性能。随后，Lewis^[9] 等人提出的 RAG 模型进一步明确了“参数化记忆 + 非参数化记忆”的统一范式，即利用生成模型作为参数化知识载体，同时通过向量索引的外部文档库提供可更新的显式知识支持，从而显著提高知识密集型任务的效果。与之相关，DPR (Dense Passage Retrieval)^[21]

则为开放域问答提供了高效的稠密检索基础，其双编码器框架在检索准确率和推理效率之间取得了良好平衡，成为后续大量 RAG 方法的默认检索组件之一。

在此基础上，研究者从不同角度扩展了基于外部文档的 RAG 的能力边界。一类工作将检索机制更深地融入语言模型架构中，例如 RETRO (Retrieval-Enhanced Transformer)^[15] 通过在语言模型解码过程中引入检索到的邻近文本块，在大规模语料库上实现了显式记忆增强，表明外部检索可以在较少参数规模下带来显著收益。另一类工作则关注少样本与上下文学习场景，例如 Atlas^[11] 通过联合训练检索器与生成模型，显著提升了知识密集型任务中的少样本学习能力；In-Context RALM (In-Context Retrieval-Augmented Language Model)^[22] 则进一步提出无需改动模型结构、仅通过检索文档并直接拼接到输入提示中的方式，即可在多种场景下获得稳定收益。这些研究共同表明，基于非结构化文本直接检索并拼接上下文的范式具有很强的通用性和工程可落地性。

尽管基于外部文档的 RAG 在开放域问答和知识增强生成中表现出良好的实用性，但其局限性也较为明显。首先，该类方法通常依赖文档块级别的语义相似度进行检索，难以显式捕捉跨文档的多跳关系，因此在复杂推理任务中容易遗漏关键证据。其次，将检索到的多个文本片段直接拼接到上下文中，往往会引入大量冗余信息和噪声，增加模型的阅读负担，影响最终生成结果的准确性与稳定性。此外，为了提高召回率，基于外部文档的 RAG 往往需要扩大检索范围或缩小切块粒度，但这又可能带来上下文割裂、语义不完整或输入长度迅速增长等问题。正是由于这些不足，后续研究开始尝试引入知识图谱、开放式信息抽取、联合语义建模等机制，以进一步提升检索增强生成在复杂场景下的推理能力与信息利用效率。

1.2.2 基于公开知识图谱的检索增强生成

为提升检索增强生成方法在复杂推理任务中的表现，研究者开始引入结构化知识以弥补纯文本检索的不足。其中，一类重要方法是直接利用已有的公开知识图谱作为外部知识源，将其与大语言模型相结合，以增强模型的推理能力与知识表达能力。

公开知识图谱通常由大规模结构化三元组构成，能够显式刻画实体及其关系，为多跳推理提供天然的结构支持。例如，在医疗领域中，SPOKE (Scalable Precision Medicine Open Knowledge Engine)^[23] 和 UMLS (Unified Medical Language System)^[24] 等大型知识图谱被广泛应用于医学问答任务，通过引入实体关系网络来辅助模型理解复杂的医学知识体系。基于此类知识图谱的 RAG 方法通常将查询映射到图谱中的相关实体，并通过图结构进行扩展检索，从而获取与问题相关的多跳知识路径。

在具体方法上，已有研究从多个角度探索了知识图谱与大语言模型的融合方式。一类方法通过构建基于知识图谱的提示信息，将图谱中的结构化知识转化为自然语言输入，从而增强模型的上下文表达能力。例如，Soman^[25]等人提出的方法通过从医学知识图谱中提取相关子图，并将其转化为提示信息，有效提升了大语言模型在医学问答任务中的表现。类似地，KG-Rank^[26]方法进一步结合知识图谱与排序机制，通过对候选答案进行图结构约束下的重排序，提高了答案选择的准确性。另一类方法则尝试将图结构直接融入检索或表示学习过程中。例如，GNN-RAG^[27]利用图神经网络（Graph Neural Network, GNN）^[28,29]对知识图谱进行编码，通过建模实体之间的结构关系，实现更加精细的语义检索。该方法能够在图结构中进行信息传播，从而更好地捕捉多跳推理所需的隐含关系，提升大语言模型的推理能力。

此外，一些通用知识图谱（如 Wikidata^[30]、DBpedia^[31]等）也被用于开放域问答任务，通过实体链接与图结构扩展，实现从结构化知识到文本生成的映射。这类方法通常依赖实体识别与链接技术，将自然语言问题中的关键实体映射到知识图谱节点，并通过关系路径搜索获取相关知识，从而为模型提供更加精准的上下文信息。尽管基于公开知识图谱的方法在提升推理能力和可解释性方面具有显著优势，但其也存在一定局限性。首先，公开知识图谱的覆盖范围有限，难以包含所有领域或最新知识，导致在开放域场景中存在知识缺失问题。其次，知识图谱的构建与维护成本较高，且不同图谱之间存在结构差异，限制了方法的通用性。此外，将结构化图谱知识转换为适合大语言模型输入的文本形式，仍然存在信息损失与表达不充分的问题。

综上所述，基于公开知识图谱的检索增强生成方法通过引入结构化知识，有效提升了模型的推理能力与解释性，但其对图谱质量与覆盖范围的依赖也限制了其在复杂开放场景中的应用。这一局限性进一步推动了后续研究从“静态知识图谱”向“动态构建知识结构”的方向发展，即通过开放式信息抽取从文本中自动构建知识图谱，从而提升方法的灵活性与适应性。

1.2.3 基于开放式信息抽取的检索增强生成

相较于直接利用 Wikidata、UMLS、SPOKE 等公开知识图谱作为外部知识源的方法，基于公开知识图谱的检索增强生成往往面临两个现实问题：一方面，公开知识图谱的覆盖范围有限，难以充分适配开放域场景；另一方面，现有公开知识图谱大多集中于医疗、生物等特定领域，通用性不足。基于此，近年来更常见的思路是利用开放式信息抽取（Open Information Extraction, OpenIE）或大语言模型，

从原始文本中动态抽取实体关系三元组，进而构建面向当前语料库的知识图谱或知识索引，以提升检索增强生成在复杂问答任务中的推理能力与适应性。

这类方法的核心思想在于：首先从文档集合中抽取实体、关系及其对应的语义单元，构建图结构或三元组集合；随后，围绕用户查询在该知识结构上执行实体扩展、路径搜索、图传播或图表示学习，以获取更具推理价值的上下文信息；最后，再将筛选后的结构化知识、对应文本证据或两者的融合结果提供给大语言模型完成答案生成。与基于外部文档的 RAG 直接基于文本块相似度进行检索不同，基于开放式信息抽取的方法能够显式建模文本内部的关系结构，因此在多跳问答、跨文档证据整合和复杂推理任务中显示出更强的潜力。

现有基于开放式信息抽取的检索增强生成研究大致可以分为以下几类。

第一类方法强调基于自动抽取三元组构建推理链，以提升多跳推理能力。**TRACE**^[32] 通过从检索文档中自动生成知识图谱，并进一步构建由多个逻辑相连三元组组成的推理链，将其作为回答问题的核心证据。该方法说明，与直接将完整检索文档输入大语言模型相比，三元组推理链能够更有效地组织分散证据，降低噪声干扰。第二类方法侧重于在特定专业领域中动态构建图谱，并通过图谱与文本的协同增强提升问答性能。例如，**DALK**^[33] 面向阿尔茨海默病科学文献场景，利用大语言模型从文献中持续抽取知识并构建演化中的领域知识图谱，同时结合粗到细采样与自感知检索机制，实现知识图谱与大语言模型的动态协同增强。类似地，**KAG**^[34] 则面向专业领域知识服务，强调知识图谱与原始文本块的双向索引、逻辑形式引导的混合推理以及知识对齐机制，以提升领域问答中的逻辑推理和专业领域知识利用能力。第三类方法将开放式信息抽取得到的图结构作为图检索或图表示学习的基础，以增强检索阶段的结构感知能力。**GraphRAG**^[35] 是这一方向的代表性工作，其首先从语料中抽取实体和关系构建知识图谱，再通过社区划分与社区摘要实现从局部到全局的问答与总结。**LightRAG**^[36] 在此基础上进一步强调轻量化与效率，通过双层检索机制同时支持低层实体检索与高层关系聚合。**KET-RAG**^[37] 则从索引成本角度出发，提出多粒度索引框架，仅对关键文本块构建知识图谱骨架，并用文本—关键词二部图作为轻量替代，以在降低构建成本的同时保持较好的检索质量。第四类方法尝试直接利用图神经网络或图基础模型对自动构建的知识结构进行建模，以提升对复杂图关系的表达能力。例如，**GFM-RAG**^[38] 提出了面向 RAG 的图基础模型，通过在大规模知识图与文档上进行预训练，增强模型在未见数据集上的泛化能力；**G-Retriever**^[39] 则关注文本图理解与问答任务，通过检索增强生成方式对图结构与文本信息进行联合建模，从而更好地支持基于图的复杂问答。第五类方法更强调记忆建模与长程知识组织。**HippoRAG**^[40] 将开放式信息

抽取得到的知识图谱与个性化 PageRank 相结合, 模拟“长期记忆”式的信息检索机制, 以支持多跳推理; HippoRAG2^[41] 在此基础上进一步引入段落节点和包含关系边, 并联合语义相似度与结构相似度, 提升检索的稳定性与事实性。与之相关, LinearRAG^[42] 重新审视了图增强检索的流程, 不再强调复杂关系图, 而是通过轻量级实体抽取与语义链接构建线性化的层级图结构, 并结合局部语义桥接与全局重要性聚合, 实现高效、抗噪的多跳检索。

1.3 本文的主要研究内容

总体来看, 基于开放式信息抽取的检索增强生成方法兼具灵活性与结构建模能力。相比直接依赖公开知识图谱的方法, 该类方法能够从原始语料中动态构建知识结构, 具有更强的领域适应性与语料可扩展性; 相比基于外部文档的朴素 RAG 方法, 又能够通过显式建模实体关系, 更好地组织多跳推理所需的证据, 从而提升复杂问答任务中的推理能力。然而, 这一类方法仍然面临若干关键挑战: 其一, 自动抽取的实体关系三元组不可避免地存在噪声与遗漏, 从而影响后续推理过程的可靠性; 其二, 图谱构建、索引维护以及路径搜索通常带来额外计算开销, 限制了方法在大规模语料场景中的效率与可扩展性; 其三, 结构化知识与原始文本语义之间仍存在表达鸿沟, 如何实现两者的高效融合, 以提升信息利用效率与生成质量, 仍是当前研究的核心问题。

针对上述问题, 本文围绕“结构分析”与“语义分析”两个关键方向, 对基于开放式信息抽取的检索增强生成方法进行了系统研究, 主要工作如下:

(1) 针对复杂多跳问答任务中上下文信噪比较低的问题, 本文提出了一种基于结构分析的检索增强生成方法。该方法首先利用大语言模型从检索文档中抽取短语结构三元组, 构建文档级短语结构三元组图; 随后, 通过迭代式路径扩展构建结构化推理路径; 在此基础上, 基于推理路径对原始文本进行精确索引, 获取与推理路径一致的文本证据, 从而构建“结构引导 + 文本补充”的上下文表示方式。该方法能够有效过滤冗余信息, 显著提升上下文信噪比, 并增强模型在复杂多跳推理任务中的表现能力。

(2) 针对基于图结构的 RAG 方法依赖复杂关系建模且构建成本较高的问题, 本文提出了一种基于结构与语义联合建模的检索增强生成方法。该方法在短语结构三元组和文本片段的基础上, 对语义表示与上下文构建过程进行系统优化: 在语义抽取阶段, 引入实体语义信息抽取, 以增强语义覆盖能力; 在表示学习阶段, 提出基于句子加权的段落表示方法, 通过加权聚合句子嵌入刻画段落内部语义分布; 在上下文构建阶段, 提出“结构 + 文本 + 语义”联合增强上下文建模方法, 将

实体、短语结构三元组与文本片段进行统一组织从而提升上下文的信息密度与表达能力。该方法在无需显式构建完整推理路径的情况下，实现了高效且稳定的性能提升。

围绕上述方法，本文在多个多跳问答基准数据集上开展了系统实验，从性能表现、消融分析、上下文构建方式以及样例分析等多个角度，对所提出方法的有效性进行了全面验证，并对不同方法在推理能力、信息利用效率与计算开销之间的权衡关系进行了深入分析。

综上所述，本文通过从结构分析与语义分析两个角度对检索增强生成方法进行改进，提出了两种互补的解决方案，为提升大语言模型在复杂多跳问答任务中的性能、效率与灵活性提供了新的研究思路。本文的研究内容框架图如图1-2所示。




图 1-2 研究内容框架图

1.4 本文组织结构

本文围绕检索增强生成方法在多跳问答任务中的结构分析与语义分析问题展

开研究，主要从结构分析与结构语义联合建模两个方面进行探索。全文共分为五个章节，具体组织结构如下：

第一章为绪论。首先从大语言模型的发展背景及其在知识密集型任务中的局限性出发，阐述检索增强生成技术的研究意义；随后对国内外相关研究现状进行分析，重点介绍朴素 RAG、基于知识图谱的 RAG 以及基于开放式信息抽取的 RAG 方法的发展情况，并在此基础上引出本文的研究问题与主要研究内容。

第二章为相关技术概述。围绕检索增强生成系统的关键组成部分，对相关基础技术进行系统介绍，包括检索增强生成方法、文本表示与向量检索技术，以及知识图谱构建技术，为后续方法设计提供理论基础。

第三章深入研究基于结构分析的检索增强生成方法。首先分析传统 RAG 在多跳推理任务中存在的上下文噪声与结构缺失等问题，随后提出通过构建短语结构三元组推理路径来引导文本检索与上下文构建的方法，并详细介绍结构化推理路径的构建与评分机制。最后通过多组实验验证该方法在提升推理能力、增强结构化分析能力与降低上下文冗余方面的有效性。

第四章深入研究基于结构与语义联合建模的检索增强生成方法。首先分析现有基于图结构的 RAG 方法构建成本高与语义表达不足等问题，以短语结构三元组和文本片段为基础，融合实体语义信息，并进一步设计基于句子加权的段落表示方法与结构增强的联合语义上下文构建方法，构建“结构 + 文本 + 语义”的联合增强上下文表示，从而提升上下文的信息密度与表达能力。通过实验分析验证该方法在无需显式推理路径的情况下，能够有效提升检索效率、推理能力与生成性能。

结论部分总结了本文在多跳问答任务中检索增强生成方法上的研究成果，分析所提方法的优势与局限，并对未来在结构分析、结构语义联合建模及复杂推理任务中的研究方向进行展望。

第 2 章 相关研究概述

2.1 引言

通过引入外部知识，RAG 有效缓解了大语言模型在知识过时与事实性错误方面的局限。然而，在知识密集型多跳推理任务等复杂场景下，现有 RAG 方法面临上下文噪声较大、语义表达不充分以及推理能力不足等问题。为提升 RAG 系统的推理能力，研究者逐渐引入结构化知识建模方法，通过构建知识图谱或语义图结构来组织检索信息，从而增强多跳推理能力。这类方法能够显式建模实体及其关系，在一定程度上改善了传统 RAG 在复杂推理任务中的表现。然而，由于知识图谱构建过程中存在信息抽取误差及结构不一致等问题，基于结构化知识的方法仍然容易引入噪声，并带来额外的计算开销。与此同时，大语言模型自身的上下文信息处理能力与复杂多跳任务推理能力，也在检索增强生成过程中发挥着重要作用。文本向量化表示与相似度检索为 RAG 提供了基础的语义匹配能力，但其容易忽略长文本内部的结构信息；命名实体识别与开放式信息抽取技术则为构建结构化知识提供了关键支撑，但也存在抽取质量不稳定的问题。如何在结构化知识与原始文本语义之间实现有效融合，成为当前研究的核心挑战之一。

基于上述背景，本章从检索增强生成技术、文本表示与向量检索技术以及知识图谱构建技术等方面，对相关研究进行系统梳理与分析，为后续研究工作提供理论基础与技术支持。

2.2 检索增强生成技术

2.2.1 朴素检索增强生成

朴素检索增强生成（Naive Retrieval-Augmented Generation）通常指这样一类方法：首先针对用户查询从外部文本语料库中检索若干相关文档或文档块，然后将这些检索结果直接拼接到提示中，最后交由大语言模型生成答案。与后续引入知识图谱、推理链或显式结构约束的方法不同，该方法主要依赖“语义检索 + 上下文拼接 + 生成回答”的基本范式完成知识增强，因此具有实现简单、部署方便和通用性强等特点。其核心思想可以概括为：利用外部非参数化知识库弥补大语言模型参数化知识的静态性与有限性，从而提升模型在知识密集型任务中的事实性与时效性。如图2-1所示，展示了朴素 RAG 的基本流程。

从技术流程上看，朴素 RAG 一般包括知识切块与索引、查询编码与召回、上




图 2-1 朴素 RAG 基本流程

下文构建以及答案生成四个环节。首先，将外部语料切分为段落级或块级文本单元，并建立稀疏或稠密索引；然后，将用户问题编码为向量表示，与候选文本块进行相似度匹配，选取得分最高的 Top-k 文档块；接着，将这些文本块按照一定顺序拼接为上下文；最后，将问题与检索上下文一并输入生成模型，输出最终答案。Lewis 等人提出的 RAG 明确给出了“参数化记忆 + 非参数化记忆”的统一框架，而 In-Context RALM 和 REPLUG^[43] 则进一步表明，即使不改动语言模型内部结构，仅通过检索文本并直接拼接到输入中，也能够获得稳定的知识增强效果。

在检索模块上，朴素 RAG 早期多依赖 BM25^[44] 等稀疏检索方法，随后逐渐转向以 DPR 为代表的稠密检索框架。DPR 使用双编码器分别对问题和文本块进行编码，并通过向量相似度实现高效检索，成为后续大量 RAG 系统的基础组件。另一方面，REALM 则更早将外部文档检索机制引入预训练阶段，证明了语言模型可以在预训练、微调和推理阶段持续访问外部知识，从而增强开放域问答能力。这些工作奠定了朴素 RAG 在“检索器 + 生成器”范式下的基本技术基础。

在生成模块上，朴素 RAG 既可以采用像 RAG 这样的“边检索边生成”方式，也可以采用将多个检索结果进行融合后再解码的方式。Izacard^[45] 等人提出的 FiD

(Fusion-in-Decoder) 通过分别编码多个检索文本块，并在解码阶段进行融合，显著提升了开放域问答性能。后续 Atlas 则在此基础上进一步展示了检索增强模型在少样本知识密集型任务中的优势，而 RETRO 则把检索更深地集成到语言模型架构中，通过从大规模文本库中检索邻近文本块增强自回归建模能力。尽管这些方法在具体实现上有所不同，但本质上仍然遵循“从文本库中直接检索证据，再将文本证据输入生成模型”的朴素 RAG 思路。

朴素 RAG 的优势在于实现路径清晰、工程成本较低，并且能够方便地接入现有大语言模型。特别是在无需改动模型内部参数或结构的场景下，In-Context RALM 与 REPLUG 这类方法展示了较强的实用价值。与此同时，由于其知识源来自可更新的外部文本库，朴素 RAG 相比纯参数化大语言模型在知识时效性、可追溯性和可维护性方面具有明显优势。

然而，朴素 RAG 的局限性同样十分突出。首先，该类方法通常基于问题与文本块之间的整体语义相似度进行检索，缺乏对实体关系和跨文档逻辑结构的显式建模，因此在多跳推理场景下容易遗漏关键证据。其次，Top- k 检索结果往往包含大量冗余和噪声，将其直接拼接到输入上下文中会增加模型的阅读负担，并可能削弱最终答案的准确性与稳定性。再次，为提升召回率而扩大检索范围时，输入 Token 数量会迅速增长，从而带来额外计算成本和上下文截断风险。正是由于这些不足，后续研究开始尝试引入知识图谱、开放式信息抽取、图检索以及联合语义建模等机制，以进一步提升检索增强生成在复杂推理任务中的能力。

2.2.2 基于知识图谱的检索增强生成

基于知识图谱的检索增强生成 (Knowledge Graph-based Retrieval-Augmented Generation, KG-RAG) 是指在传统检索增强生成框架中，引入知识图谱作为知识组织与检索载体，从而提升大语言模型在复杂问答与多跳推理任务中的知识利用能力。与朴素 RAG 直接对文本块进行相似度检索不同，KG-RAG 通过显式建模实体、关系及其连接结构，将原本分散在文档中的知识组织为可计算的图结构，使检索过程不仅能够返回“相关文本”，还能够提供“结构化证据”与“关系路径”。这使得模型在面对跨文档、多实体和多步推理问题时，能够更容易捕捉关键线索并形成可解释的推理过程。从知识来源角度来看，基于知识图谱的检索增强生成方法主要可以分为两类：一类是直接利用已有的公开知识图谱作为外部知识源，另一类则是从原始文本中自动构建知识图谱以支持动态检索。

首先，基于公开知识图谱的方法通常依赖已有的大规模结构化知识库，如 Wikidata、DBpedia、UMLS 或 SPOKE 等。这类方法通过实体链接将用户问题中的关键

查找与问题相关的结构化证据。最后，再将这些图证据以路径、子图、摘要或图文融合上下文的形式输入大语言模型，以支持最终答案生成。

在知识组织层面，知识图谱为 RAG 提供了显式的关系结构，这一点是其区别于朴素 RAG 的核心特征。传统文本检索依赖整体语义相似度，容易忽略实体之间的组合关系，而知识图谱则能够以三元组或子图形式保留“谁与谁存在何种关系”的结构信息。例如，GraphRAG 通过先构建实体图，再利用社区划分与社区摘要实现由局部到全局的知识组织，适合处理需要面向整个语料集合进行总结和全局分析的问题；HippoRAG 则通过知识图谱和个性化 PageRank 模拟长期记忆检索机制，使得检索过程能够沿着图结构完成多跳扩展，其框架如图2-3所示；LightRAG 强调图结构上的低层实体检索与高层关系聚合，兼顾信息覆盖与检索效率。




图 2-3 HippoRAG 框架^[40]

在检索机制层面，KG-RAG 往往不再局限于一次性的 Top- k 文本块召回，而是将检索过程扩展为“实体定位—结构扩展—证据聚合”的多阶段过程。典型做法包括：以问题中的实体为起点，在图中搜索相关邻居和关系路径；以图神经网络对局部子图进行编码，从而获取更加紧凑的检索表示；或通过图上的排序与传播机制，估计不同节点、边和路径的重要性。GNN-RAG 便是这一思路的代表，该方法利用图神经网络在知识图谱子图上执行稠密推理，先找到候选答案，再抽取连接问题实体与候选答案的最短路径，并将其语言化后输入大语言模型，从而实现“图推理 + 文本生成”的协同。类似地，GFM-RAG 则尝试利用图基础模型增强图表示与图检索能力，以改善复杂图结构上的泛化效果。

在上下文构建层面，基于知识图谱的方法通常会将结构化知识与文本证据结合使用，而不是仅返回图中的节点或边。一方面，知识图谱中的路径、子图和社区摘要能够为问题提供更清晰的逻辑框架；另一方面，原始文本仍然承载着更丰富的语义细节。为此，许多 KG-RAG 方法采用“结构化检索 + 文本补充”的方式构建提示。例如，GraphRAG 使用社区摘要作为全局上下文，HippoRAG 将图上的传播结果与文本证据结合，LightRAG 则通过图结构引导文本检索，增强上下文的可解释性与完整性。可以看出，知识图谱在这类方法中并非替代文本，而是作为组织和筛选文本的重要中介。

基于知识图谱的检索增强生成具有多方面优势。首先，它能够显式建模实体关系，从而更适合多跳问答、复杂推理和跨文档证据聚合等任务。其次，图结构本身具有较强的可解释性，便于分析模型回答所依赖的路径和证据来源。再次，通过图上的路径搜索、传播和聚合，能够在一定程度上缓解朴素 RAG 中“仅按表面语义相似度检索”导致的证据割裂问题。但与此同时，KG-RAG 也存在明显局限。其一，知识图谱的质量直接决定检索与推理效果，如果图中存在抽取错误、实体歧义或结构断裂，则可能将错误信息传播到后续回答过程中。其二，图谱构建、图表示学习与图检索通常会带来额外的时间与存储成本，尤其是在大规模语料场景下，这一问题更为突出。其三，尽管图结构有利于表达关系，但结构化表示本身较为稀疏，往往不足以替代原始文本中的丰富语义，因此如何高效融合“图结构”和“文本上下文”，仍然是该方向中的关键问题。

2.3 文本表示与向量检索技术

文本表示与向量检索是检索增强生成系统的基础环节，其核心目标是将自然语言文本映射到可计算的表示空间，并通过相似度计算实现高效检索。在传统信息检索中，文本通常采用基于词频统计的稀疏表示方法，如 BM25 等模型。这类方法具有实现简单、可解释性强的优点，在关键词匹配明确的场景中依然表现稳定；但由于其主要依赖词项重叠，难以刻画深层语义关联，因此在语义表达丰富、措辞多样或需要隐式推理的任务中存在明显局限。

随着预训练语言模型的发展，文本表示逐渐从稀疏词袋表示转向稠密向量表示。早期的 BERT^[46] 类模型虽然具备较强的上下文建模能力，但直接用于语义相似度计算时效率较低。为此，Reimers^[47] 等人提出了 Sentence-BERT (SBERT)，通过孪生网络结构学习句子级向量表示，使文本能够直接在向量空间中进行相似度比较，大幅提升了语义检索与聚类等任务的效率。此后，MPNet^[48] 进一步结合掩

码语言建模与排列语言建模的优点，提高了预训练表示的语义质量，也成为后续多种句向量模型的重要基础。

在检索任务中，稠密表示通常通过双编码器（dual-encoder）框架实现。其基本思想是分别对查询和候选文本进行独立编码，再通过向量内积或余弦相似度计算两者相关性。DPR 是这一方向的代表性工作，其表明仅依赖稠密向量检索便能够在开放域问答任务中显著优于传统 BM25 基线。近年来，随着通用文本嵌入模型的发展，E5^[49] 等模型通过弱监督对比学习进一步提升了向量表示的泛化能力，在检索、聚类 and 分类等多种任务上表现出较强的迁移性能。这使得文本嵌入模型逐渐成为现代检索增强生成系统中的核心组件。

在相似度计算方面，向量检索通常采用内积（inner product）或余弦相似度（cosine similarity）作为度量标准。设查询向量为 $\mathbf{q} \in \mathbb{R}^d$ ，候选文本向量为 $\mathbf{d} \in \mathbb{R}^d$ ，则内积相似度定义为：

$$\text{sim}_{\text{dot}}(\mathbf{q}, \mathbf{d}) = \mathbf{q}^T \mathbf{d} = \sum_{i=1}^d q_i d_i, \quad (2-1)$$

其中， $\text{sim}_{\text{dot}}(\mathbf{q}, \mathbf{d})$ 表示查询向量与候选向量之间的内积相似度， $\mathbf{q}^T \mathbf{d}$ 表示向量点积运算， q_i 和 d_i 分别表示查询向量与候选向量在第 i 维上的取值， d 表示向量空间的维度。

余弦相似度则在内积基础上对向量进行归一化处理，其定义为：

$$\text{sim}_{\text{cos}}(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q}^T \mathbf{d}}{\|\mathbf{q}\| \|\mathbf{d}\|}, \quad (2-2)$$

其中， $\text{sim}_{\text{cos}}(\mathbf{q}, \mathbf{d})$ 表示查询向量与候选向量之间的余弦相似度， $\|\mathbf{q}\|$ 和 $\|\mathbf{d}\|$ 分别表示向量 $\mathbf{q}$ 与 $\mathbf{d}$ 的 ℓ_2 范数。

在实际应用中，当向量经过归一化处理后，内积相似度与余弦相似度在排序效果上通常等价，因此常使用内积来实现更高效的计算。

由于大规模语料库中的候选文本数量通常非常庞大，若直接对所有向量逐一比对，将带来较高的时间开销。因此，研究者通常借助近似最近邻（Approximate Nearest Neighbor, ANN）索引技术提升检索效率。FAISS^[50] 是这一方向中应用最广泛的工具之一，它支持多种高维向量索引与加速检索策略，能够在保证较高召回率的同时显著降低大规模相似度搜索的计算成本。

尽管基于文本嵌入的向量检索方法在语义匹配方面具有显著优势，但其局限性同样值得关注。首先，单一向量表示通常会将整段文本压缩为统一语义表示，难以显式反映文本内部不同句子或不同语义单元的重要性差异。其次，基于整体语义相似度的检索方式虽然能够提高召回能力，但也可能引入与问题仅在表面语义

上相关、而在推理层面并不关键的文本片段。尤其是在多跳问答场景中，如果缺乏对实体、短语或局部语义结构的进一步建模，仅依赖整体向量表示容易导致关键证据被淹没于冗余上下文中。正因如此，如何在向量检索的基础上进一步引入更细粒度的语义表示与结构化建模，成为本文后续研究的重要出发点。

2.4 知识图谱构建技术

命名实体识别（Named Entity Recognition, NER）与开放式信息抽取是构建结构化知识表示的重要基础技术。前者主要负责从自然语言文本中识别具有明确语义指称的实体片段及其类别，如人名、地名、机构名、时间表达等；后者则进一步从句子中抽取开放域关系事实，通常表示为三元组或关系元组形式。二者共同构成了从非结构化文本中获取结构化知识的关键途径，并被广泛应用于知识图谱构建、问答系统、信息检索和检索增强生成等任务。

2.4.1 命名实体识别技术

命名实体识别的目标是：给定一个输入文本序列

$$X = \{x_1, x_2, \dots, x_n\}, \quad (2-3)$$

其中， X 表示长度为 n 的输入文本序列， x_i 表示序列中的第 i 个词或子词单元， n 表示输入序列的总长度。预测与之对应的标签序列

$$Y = \{y_1, y_2, \dots, y_n\}, \quad (2-4)$$

其中， Y 表示与输入序列对应的标签序列， y_i 表示第 i 个词或子词对应的实体标签。实际系统中通常采用 BIO 或 BIOES 等标注方案，将实体边界识别与实体类别判断统一为序列标注问题。其目标可以形式化表示为

$$Y^* = \arg \max_Y P(Y | X), \quad (2-5)$$

其中， Y^* 表示在给定输入序列 X 条件下的最优标签序列， $P(Y | X)$ 表示标签序列 Y 在输入序列 X 条件下的条件概率， $\arg \max$ 表示选择使条件概率最大的标签序列。

早期命名实体识别方法主要依赖人工设计特征和统计学习模型，如条件随机场（Conditional Random Field, CRF）等。这类方法需要结合词性、词形、上下文窗口以及词典特征进行建模，具有较强可解释性，但对特征工程依赖较强，迁移能力有限。随着深度学习的发展，基于双向长短期记忆网络（BiLSTM）与 CRF 的神经序列标注模型逐渐成为主流^[51]。Lample 等人提出的 BiLSTM-CRF 架构表明，在无

需复杂人工特征的前提下，仅利用字符级表示与词向量即可在多个 NER 基准上取得优异效果。

在此基础上，预训练语言模型进一步推动了 NER 技术的发展。BERT 通过双向 Transformer 预训练获得上下文相关表示，使得 NER 能够充分利用更丰富的上下文语义信息。基于 BERT 的命名实体识别通常将输入文本编码为上下文向量，再在输出层进行逐位置分类，或结合 CRF 层建模标签之间的依赖关系。BERT 及其变体在命名实体识别任务中显著提升了性能，尤其适用于上下文依赖较强的复杂实体识别场景。

从本文研究内容来看，命名实体识别的作用主要体现在两个方面：一方面，它是构建图结构或语义索引的起点，能够从原始文本中定位关键实体节点；另一方面，在后续联合语义建模中，实体通常也是最基本、最稳定的语义单元。需要指出的是，NER 虽然能够较好地识别显式实体，但其识别对象通常局限于具有明确边界和类型的命名实体，对于“政策变化”“神经网络结构”等不一定属于标准命名实体但具有重要语义价值的短语级概念，覆盖能力相对不足。这也是后续需要引入短语抽取等更细粒度语义建模方式的重要原因。

2.4.2 开放式信息抽取技术

开放式信息抽取的目标是从任意领域文本中自动抽取关系事实，而不预先限定关系模式。与传统关系抽取需要预定义关系类别不同，OpenIE 更强调开放域、可扩展和领域无关的抽取能力。给定一句自然语言文本 s ，OpenIE 系统通常输出若干关系事实：

$$\mathcal{T}(s) = \{(h_1, r_1, t_1), (h_2, r_2, t_2), \dots, (h_m, r_m, t_m)\}, \quad (2-6)$$

其中， $\mathcal{T}(s)$ 表示从文本 s 中抽取出的关系三元组集合， (h_i, r_i, t_i) 表示第 i 个抽取出的关系事实， h_i 表示头实体或主语成分， r_i 表示关系短语， t_i 表示尾实体或宾语成分， m 表示文本中抽取得到的关系事实总数。对于整个文档集合 $\mathcal{D} = \{d_1, d_2, \dots, d_k\}$ ，可进一步得到三元组总集合

$$\mathcal{T}_{\mathcal{D}} = \bigcup_{i=1}^k \mathcal{T}(d_i), \quad (2-7)$$

其中， $\mathcal{D}$ 表示包含 k 个文档的文档集合， d_i 表示第 i 个文档， $\mathcal{T}(d_i)$ 表示从文档 d_i 中抽取出的三元组集合， $\mathcal{T}_{\mathcal{D}}$ 表示整个文档集合中的全局关系三元组集合。

OpenIE 的代表性工作可以追溯到 Etzioni^[52] 等人提出的 TextRunner 框架，其核心思想是从海量文本中自动抽取开放域关系，而不依赖预定义关系模板。这一

工作被普遍视为开放式信息抽取方向的开端。随后, Schmitz^[53] 等人提出 OLLIE, 在依存句法分析基础上进一步提升了抽取质量, 能够处理更加复杂的语义结构, 如归因关系和条件关系, 从而显著增强了开放式抽取的表达能力。

从技术实现上看, OpenIE 方法大致可以分为三类。第一类是基于规则与模式匹配的方法, 通过句法模板、依存路径和启发式规则抽取关系; 第二类是基于监督或弱监督学习的方法, 通过自动构造训练数据学习抽取器; 第三类是近年来兴起的基于大语言模型的方法, 即通过指令提示或上下文学习, 直接让大语言模型从句子或段落中生成关系三元组。相较于传统 OpenIE, 基于 LLM 的方法在复杂句法和跨句语义理解方面具有更强能力, 也更容易适配不同领域语料, 因此在近年来的知识图谱构建与图增强 RAG 研究中被广泛采用。

在检索增强生成场景下, 开放式信息抽取的主要作用是: 将原始文本中的隐式知识关系转化为显式的结构化表示。这样一来, 系统可以围绕实体、关系和路径进行检索、扩展和重排序, 而不再仅依赖文本块级别的整体语义相似度。尤其是在多跳问答任务中, OpenIE 提供的三元组能够帮助系统显式组织跨文档证据, 从而增强推理能力和可解释性。

从技术流程上看, 命名实体识别与开放式信息抽取具有明显的层次关系。命名实体识别更关注“识别文本中的关键实体单元”, 而开放式信息抽取则进一步关注“识别实体之间的关系及其事实表达”。前者为后者提供候选语义节点, 后者则为前者补充结构化关系信息。可以将两者的关系概括为:

$$\text{Text} \xrightarrow{\text{NER}} \text{Entities} \xrightarrow{\text{OpenIE}} \text{Triples / Graph}, \quad (2-8)$$

其中, Text 表示原始输入文本, NER 表示命名实体识别过程, 用于从文本中识别关键实体, Entities 表示抽取出的实体集合, OpenIE 表示开放式信息抽取过程, 用于识别实体之间的关系, Triples / Graph 表示最终生成的结构化三元组集合或知识图谱。

然而, 随着大语言模型的发展, 传统的“先实体识别、再关系抽取”的流水线式处理方式逐渐被统一建模方式所替代。在基于大语言模型的开放式信息抽取中, 模型可以直接从原始文本中同时识别实体及其关系, 即在无需显式命名实体识别模块的情况下, 直接生成结构化三元组:

$$\text{Text} \xrightarrow{\text{LLM-based OpenIE}} \text{Triples}, \quad (2-9)$$

其中, LLM-based OpenIE 表示基于大语言模型的开放式信息抽取过程, 该过程直接从原始文本中统一完成实体识别与关系抽取任务, Triples 表示最终输出的结构化关系三元组集合。

该方式利用大语言模型强大的上下文理解能力，将实体识别与关系抽取过程进行隐式融合，能够更好地处理复杂句法结构与跨句语义关系，因此在近年来的知识图谱构建与图增强检索方法中得到广泛应用。然而，该类方法也存在一定局限，例如生成结果的稳定性较弱、结构约束不足以及容易引入噪声等问题。因此，在实际系统设计中，仍需根据任务需求在“显式分阶段抽取”和“统一生成式抽取”之间进行权衡。

总体而言，命名实体识别与开放式信息抽取是从非结构化文本中构建结构化知识的两项基础技术。命名实体识别适合提取稳定、明确的核心语义节点，而开放式信息抽取则能够进一步揭示实体之间的关系结构，为多跳推理和图增强检索提供支持。与此同时，这两类技术也各自存在局限：NER 对短语级、概念级语义覆盖不足，OpenIE 则容易受到抽取噪声和关系表达不稳定的影响。如何根据具体任务需求，在实体、短语、三元组与原始文本之间建立更高效的协同关系，是后续方法设计中的关键问题。

2.5 本章小结

本章系统梳理了本文研究所涉及的核心理论基础与关键支撑技术。首先，介绍了朴素检索增强生成方法的基本框架及其在知识增强方面的优势与局限；其次，分析了基于知识图谱的检索增强生成方法，通过结构化建模提升多跳推理能力，同时指出其在图谱质量与计算开销方面的挑战；随后，介绍了文本表示与向量检索技术，为高效语义匹配与大规模检索提供基础支撑；最后，介绍了知识图谱构建技术中的命名实体识别与开放式信息抽取方法，为后续结构化知识构建提供必要的技术支撑。

第 3 章 基于结构分析的检索增强生成方法

3.1 引言

大语言模型凭借其强大的语义理解能力和海量预训练知识，在多种任务中取得了突破性进展。然而，在需要实时知识与精确推理的知识密集型任务中，LLMs 仍然存在固有局限性。其中最主要的问题在于其知识具有静态性，受限于训练数据的时间截断，容易导致知识过时。为了解决这一问题，检索增强生成被提出作为一种有效方案。RAG 通过从外部知识库中动态检索相关内容并作为上下文构建输入，从而缓解模型的知识陈旧问题，并显著提升模型在事实性问答任务中的准确性。然而，标准 RAG 方法主要依赖语义相似度进行检索，往往会引入大量无关信息，从而降低上下文的信噪比，影响推理效果。




图 3-1 LLM 在复杂推理任务中的典型工作流程

为了解决文本上下文中信噪比较低的问题，研究者开始尝试将知识图谱引入 RAG 框架。知识图谱通常通过 OpenIE 从非结构化文本中自动抽取关系，并以三元组形式组织知识。这种结构化表示能够提供清晰的推理框架，使模型能够更快地

捕捉核心信息并沿着明确的推理路径进行推断。然而，现有的基于知识图谱增强的 RAG 方法（KG-RAG）仍然面临以下关键挑战：

（1）多跳推理路径的脆弱性：在自动构建且存在噪声的知识图谱上进行多跳推理具有较大难度。错误关系或缺失连接可能导致推理路径中断，从而影响推理的完整性。

（2）三元组语义稀疏性：尽管知识图谱三元组提供了清晰的结构框架，但其语义信息通常较为简洁，缺乏丰富的上下文细节与解释能力。这种语义稀疏性限制了模型生成复杂和全面答案的能力。

（3）图结构利用不足：大多数 KG-RAG 方法仅将知识图谱作为检索索引，获取离散的三元组集合，并将其简单拼接后输入模型，忽略了图中丰富的拓扑结构信息，而这些结构信息对于复杂推理至关重要。

如图3-1所示，针对上述问题，本章提出一种基于结构分析的文本检索增强生成方法——Triple-Guided Text Retrieval-Augmented Generation（TTRAG）。与传统 RAG 方法直接检索非结构化文本，或 KG-RAG 方法使用离散三元组不同，TTRAG 提出了一种“两阶段融合”框架。该方法首先基于查询构建高质量的短语结构三元组推理路径，然后在此结构化推理路径基础上引入精确的文本上下文进行补充。




图 3-2 TTRAG 整体框架

图3-2展示了模型 TTRAG 的整体框架，TTRAG 专为复杂的推理任务而设计。它首先构建短语结构三元组的结构化推理路径，以确保逻辑严密的推理路径。然后，它对该结构化推理路径进行上下文证据索引得到最相关的文本内容，从而提供丰富的语义信息，实现高效准确的推理。与其他 RAG 方法相比，TTRAG 具有部分可解释性，并提供清晰、渐进的推理路径。相较于基线方法，TTRAG 可减少约 70%-80% 的提示词长度，显著降低了上下文中的噪声干扰并提升其知识密度。

这种“先构建推理路径、再进行语义增强”的策略，不仅为模型提供了清晰且可验证的推理路径，同时弥补了结构化知识语义表达不足的问题，实现了结构化知识与非结构化文本的有效融合。

本章组织结构如下：3.2 节介绍短语结构三元组图构建。3.3 节介绍基于短语结构三元组的结构化推理路径构建。3.4 节介绍基于结构化推理路径的上下文证据索引。3.5 节介绍实验结果与分析。3.6 节为本章小结。

3.2 短语结构三元组图构建

如图3-4所示，本文方法首先从大规模文档集合中检索与用户查询最相关的前 k 个候选文档，随后利用大语言模型执行开放式信息抽取，从候选文档中抽取能够反映文本核心事实的短语结构三元组，并进一步构建查询相关的文档级短语结构三元组图（Phrase-Structured Triple Graph）。该过程实现了从非结构化文本到结构化知识表示的转换，为后续结构化推理路径构建提供了基础。

3.2.1 短语结构三元组图表示

不同于传统知识图谱通常依赖预定义实体与关系模式，本文构建的知识结构主要来源于开放域文本中的事实抽取结果，因此更适合表示为短语结构三元组图。形式上，可将其表示为：

$$\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{T}), \quad (3-1)$$

其中， $\mathcal{E}$ 表示节点集合，可包含命名实体、事件描述或关键语义短语； $\mathcal{R}$ 表示关系集合； $\mathcal{T}$ 表示短语结构三元组集合，即：

$$\mathcal{T} \subseteq \mathcal{E} \times \mathcal{R} \times \mathcal{E}, \quad (3-2)$$

每个短语结构三元组 (h, r, t) 表示一条结构化事实，其中头节点 h 可以是文档标题、主题实体或核心概念，尾节点 t 可以是文本中的实体、属性、事件或语义短语， r 表示两者之间的语义关系。因此，本文中的短语结构三元组并不局限于狭义的实体关系对，而是更广义的开放域知识表达单元。

定义 3.1 结构化推理路径（Structured Reasoning Path） 在短语结构三元组图 $\mathcal{G}$ 中，结构化推理路径是由多个相互连接的短语结构三元组组成的有序序列，用于表示从问题相关起点到答案相关终点的多跳推理过程。长度为 l 的结构化推理路径可表示为：

$$C(e_0, e_l) = \langle (e_0, r_1, e_1), (e_1, r_2, e_2), \dots, (e_{l-1}, r_l, e_l) \rangle, \quad (3-3)$$

其中, $e_i \in \mathcal{E}$, $r_j \in \mathcal{R}$ 。相邻短语结构三元组通过共享节点相连接, 形成连续的结构化推理路径。该路径能够显式刻画复杂问题中的多跳推理逻辑, 并为后续答案生成提供可解释的结构基础。

任务定义: 给定自然语言问题 q 与短语结构三元组图 $\mathcal{G}$, 本章任务旨在从图中检索与问题相关的结构化推理路径集合:

$$C_q = \{C_1, C_2, \dots, C_m\}, \quad (3-4)$$

并进一步结合对应文本证据生成最终答案:

$$f(\text{LLM} \mid q, C_q) \rightarrow \mathcal{A}_q, \quad (3-5)$$

其中, $\mathcal{A}_q$ 表示针对问题 q 的答案。通过显式结构化推理路径, 模型能够在保持知识可解释性的同时提升复杂推理能力。

文档检索: 给定查询 q 与文档集合 $\mathcal{D}$, 首先利用检索器 $\mathcal{R}$ 获取相关性最高的前 k 个文档:

$$\mathcal{D}_k = \mathcal{R}(q, \mathcal{D}, k), \quad (3-6)$$

其中, $\mathcal{D}_k = \{d_1, d_2, \dots, d_k\}$ 。

检索器可采用稠密向量编码器将查询与文档映射为向量表示:

$$\mathbf{q} = \text{Enc}(q), \quad \mathbf{d}_i = \text{Enc}(d_i), \quad (3-7)$$

其中, $\mathbf{q}$ 表示查询 q 的向量表示, $\mathbf{d}_i$ 表示第 i 个文档 d_i 的向量表示, $\text{Enc}(\cdot)$ 表示文本编码器函数, 用于将输入文本映射至高维语义向量空间。

利用余弦相似度计算相关性:

$$\text{sim}(q, d_i) = \frac{\mathbf{q} \cdot \mathbf{d}_i}{\|\mathbf{q}\| \|\mathbf{d}_i\|}, \quad (3-8)$$

其中, $\text{sim}(q, d_i)$ 表示查询 q 与文档 d_i 之间的语义相似度, $\mathbf{q} \cdot \mathbf{d}_i$ 表示向量内积, $\|\mathbf{q}\|$ 与 $\|\mathbf{d}_i\|$ 分别表示对应向量的 ℓ_2 范数。

最终选取得分最高的前 k 个文档作为结构化知识抽取基础。

3.2.2 短语结构三元组抽取

在获得候选文档后, 采用大语言模型作为短语结构三元组生成器 g , 基于上下文学习提示执行开放式信息抽取。具体而言, 对于每个文档 d_i :

$$\mathcal{T}_i = g(d_i), \quad (3-9)$$

其中, $\mathcal{T}_i$ 表示文档 d_i 中抽取的短语结构三元组集合, $g(\cdot)$ 表示基于大语言模型的短语结构三元组生成函数。

短语结构三元组抽取提示模板如图3-3所示, 通过标题引导与文本内容结合, 提升事实抽取的一致性与结构稳定性。




图 3-3 短语结构三元组抽取提示模板

3.2.3 短语结构三元组图构建

聚合所有候选文档的短语结构三元组集合:

$$\mathcal{T}_D = \bigcup_{i=1}^k \mathcal{T}_i, \quad (3-10)$$

进一步构建文档级短语结构三元组图:

$$\mathcal{G}_D = (\mathcal{E}_D, \mathcal{R}_D, \mathcal{T}_D), \quad (3-11)$$

其中, $\mathcal{G}_D$ 表示基于候选文档集合构建的文档级知识图谱, $\mathcal{E}_D$ 、 $\mathcal{R}_D$ 、 $\mathcal{T}_D$ 分别表示节点、关系与短语结构三元组集合。

此外, 本文为每个短语结构三元组保留其原始文本位置映射, 包括文档编号、段落位置与句子级索引。这一设计保证了结构化知识与原始文本之间的可追溯性, 使后续章节能够基于结构化推理路径高效回溯相关文本证据, 实现结构分析与文本语义的深度融合。

3.3 基于短语结构三元组的结构化推理路径构建

如图3-4所示, 在构建文档级短语结构三元组图 $\mathcal{G}_D = (\mathcal{E}_D, \mathcal{R}_D, \mathcal{T}_D)$ 的基础上, 本章进一步提出一种基于短语结构三元组路径的推理路径构建方法, 用于支持多跳推理过程。所谓推理路径, 是由一系列有序连接的短语结构三元组构成的路径结构, 能够刻画从问题到答案的逐步推理过程。TTRAG 通过迭代式路径扩展、基




图 3-4 TTRAG 框架图

于大语言模型的短语结构三元组选择以及束搜索^[54]（Beam Search）策略，实现了高效且可靠的推理路径构建。

3.3.1 短语结构三元组表示与编码

给定问题 q 及其对应的短语结构三元组集合 $\mathcal{T}_D = \{t_1, t_2, \dots, t_n\}$ ，其中每个短语结构三元组表示为 $t = (h, r, o)$ ，本章首先将所有短语结构三元组编码为稠密向量表示：

$$\mathbf{E}_T = \{\mathbf{e}_{t_1}, \dots, \mathbf{e}_{t_n}\}, \quad (3-12)$$

其中， $\mathbf{E}_T$ 表示短语结构三元组集合的向量表示集合， $\mathbf{e}_{t_i}$ 表示短语结构三元组 t_i 的稠密语义向量表示。

该编码过程通过预训练语义编码模型实现，并在整个推理过程中复用，从而避免重复计算，提高整体效率。

3.3.2 迭代式路径扩展

推理路径通过逐步扩展路径的方式构建。在第 j 跳（hop）时，当前部分路径可表示为：

$$\mathcal{P}^{(j)} = \{t_{p_1}, \dots, t_{p_j}\}, \quad (3-13)$$

其中， $\mathcal{P}^{(j)}$ 表示当前第 j 跳时的部分推理路径， t_{p_k} 表示路径中第 k 个被选中的短语结构三元组。

为了结合已有推理信息与原始问题，本章将当前路径与问题进行拼接，构造新的查询：

$$q^{(j)} = \text{Concat}(\mathcal{P}^{(j)}, q), \quad (3-14)$$

其中， $q^{(j)}$ 表示第 j 跳时的扩展查询， $\text{Concat}(\cdot)$ 表示路径信息与原始问题的拼接操作。

将构造的新的查询编码为查询向量 $\mathbf{e}_{q^{(j)}}$ 。随后，通过计算查询向量与候选短语结构三元组向量之间的相似度（采用内积形式）得到每个候选短语结构三元组的相关性得分：

$$s_i^{(j)} = \mathbf{e}_{q^{(j)}}^\top \mathbf{e}_{t_i}, \quad (3-15)$$

其中， $s_i^{(j)}$ 表示第 j 跳时候选短语结构三元组 t_i 的相关性得分， $\mathbf{e}_{q^{(j)}}$ 表示扩展查询 $q^{(j)}$ 的向量表示， $\mathbf{e}_{t_i}$ 表示候选短语结构三元组 t_i 的向量表示。

为避免路径中出现重复短语结构三元组，本章对当前路径中已选取的短语结构三元组进行掩码处理。随后选取得分最高的前 m 个短语结构三元组构成候选集合：

$$\mathcal{C}^{(j)} = \text{Top-}m(\{s_i^{(j)}\}), \quad (3-16)$$

其中， $\mathcal{C}^{(j)}$ 表示第 j 跳的候选短语结构三元组集合， $\text{Top-}m(\cdot)$ 表示按照相关性得分排序后选取前 m 个候选项的操作， m 表示每轮保留的候选短语结构三元组数量。该过程实现了基于语义匹配的候选路径扩展。

3.3.3 基于大语言模型的短语结构三元组选择

在获得候选短语结构三元组集合 $\mathcal{C}^{(j)}$ 后，本章进一步引入大语言模型对候选路径进行语义判断。具体而言，将当前路径 $\mathcal{P}^{(j)}$ 与候选集合构造成多选提示（multi-choice prompt），并利用开源大语言模型作为短语结构三元组选择器。推理路径构建提示模板如图3-5所示。

模型输出每个候选短语结构三元组的选择概率，以及一个特殊的终止选项 STOP：

$$P(c \mid \mathcal{P}^{(j)}, q), \quad c \in \mathcal{C}^{(j)} \cup \{\text{STOP}\}, \quad (3-17)$$

其中， $P(c \mid \mathcal{P}^{(j)}, q)$ 表示在当前推理路径 $\mathcal{P}^{(j)}$ 和问题 q 条件下选择候选项 c 的条件概率， $\mathcal{C}^{(j)}$ 表示第 j 跳的候选短语结构三元组集合， c 可以是候选集合中的某一短语结构三元组，也可以是特殊终止选项 STOP，STOP 表示当前推理路径无需继续扩展。当模型选择 STOP 时，表示当前推理路径已经完成。




图 3-5 推理路径构建提示模板

该机制结合了语义相似度与语言模型的推理能力，使路径扩展更加符合自然语言语义逻辑。

3.3.4 基于束搜索的并行路径扩展

为同时探索多条潜在推理路径，本章采用束搜索策略，在每一步最多保留 B 条候选路径。

对于每一条未完成路径，从候选集合中选取概率最高的前 M 个扩展分支，并计算路径的累积得分：

$$\text{Score}(\mathcal{P}^{(j+1)}) = \text{Score}(\mathcal{P}^{(j)}) \cdot P(c \mid \mathcal{P}^{(j)}, q), \quad (3-18)$$

其中， $\text{Score}(\mathcal{P}^{(j)})$ 表示当前第 j 跳路径的累积得分， $\text{Score}(\mathcal{P}^{(j+1)})$ 表示扩展后路径的累积得分， $P(c \mid \mathcal{P}^{(j)}, q)$ 表示在当前路径与问题条件下选择候选扩展项 c 的概率。

同时，为抑制低质量路径的扩展，本章引入阈值 δ ，过滤掉概率低于该阈值的候选分支，从而减少噪声传播。所有扩展路径按照累积得分进行排序，并保留前 B 条路径进入下一轮扩展。

3.3.5 路径终止与推理路径生成

当满足以下任一条件时，路径被标记为完成：

- (1) 模型选择 STOP；
- (2) 达到预设定的超参数最大跳数 L 。

最终得到的推理路径集合表示为：

$$\mathcal{S} = \{(\mathcal{P}_1, s_1), \dots, (\mathcal{P}_B, s_B)\}, \quad (3-19)$$

其中, $\mathcal{P}_i$ 表示一条推理路径, s_i 表示其对应的置信得分。

上述推理路径为后续答案生成提供了结构化、可解释的推理依据, 同时显著提升了推理过程的可靠性与可控性。

3.4 基于结构化推理路径的上下文证据索引

3.4.1 文本证据索引

在第 3.2 节的短语结构三元组图构建过程中, 本章利用大语言模型作为短语结构三元组图生成器 g , 对检索得到的文档集合 $\mathcal{D}_k$ 构建文档级短语结构三元组图。具体而言, 对于每个文档, 构建对应的短语结构三元组图子图, 并为每个短语结构三元组记录其来源信息, 包括原始文档、段落以及句子级别的位置索引。

在推理路径 $\mathcal{S}$ 构建完成后, 本章进一步引入文本证据以增强语义表达能力。对于推理路径中的每一个短语结构三元组 $\tau = (h, r, t)$, 定义其对应的文本映射函数为:

$$\mathcal{M}(\tau) = \{d_\tau, p_\tau, s_\tau\}, \quad (3-20)$$

其中, $\mathcal{M}(\tau)$ 表示短语结构三元组 τ 的文本映射结果, d_τ 表示短语结构三元组来源文档, p_τ 表示短语结构三元组所在段落, s_τ 表示与该短语结构三元组语义对应的文本信息, h 、 r 、 t 分别表示头实体、关系和尾实体。

基于该映射关系, 可以从原始文档中精确定位与短语结构三元组相关的文本证据。进一步地, 对于一条推理路径 $\mathcal{P} = \{\tau_1, \tau_2, \dots, \tau_l\}$, 其对应的文本证据集合定义为:

$$\mathcal{E}(\mathcal{P}) = \bigcup_{i=1}^l \mathcal{M}(\tau_i), \quad (3-21)$$

其中, $\mathcal{E}(\mathcal{P})$ 表示推理路径 $\mathcal{P}$ 对应的文本证据集合, τ_i 表示路径中的第 i 个短语结构三元组, l 表示路径长度, $\bigcup$ 表示对路径中所有短语结构三元组对应文本映射结果的聚合操作。

图3-6 展示了检索到的原始文本块中过滤出仅包含知识的句子的方式。通过仅保留包含核心知识的句子, 本章方法在保证语义完整性的同时, 能够显著减少无关文本信息干扰, 提高知识密度, 从而大幅减少上下文长度, 即最终输入 LLM 的提示词长度, 为后续答案生成提供更加精确且可解释的输入。

3.4.2 证据链编排

在完成推理路径构建与上下文证据索引后, TTRAG 将结构化知识与文本证据




图 3-6 利用短语结构三元组推理路径过滤原始文本段落得到包含知识的句子

进行融合，并与用户问题共同构建提示（Prompt），输入至大语言模型以生成最终答案。该过程可形式化表示为：

$$\mathcal{A}_q = f_{\text{LLM}}(q, \mathcal{S}, \mathcal{C}), \quad (3-22)$$

其中， $f_{\text{LLM}}(\cdot)$ 表示作为答案生成器的大语言模型， $\mathcal{A}_q$ 表示模型输出的最终答案， q 表示用户查询， $\mathcal{S}$ 表示推理路径集合， $\mathcal{C}$ 表示基于推理路径索引得到的上下文证据文本。

与传统基于图的 RAG 方法不同，后者通常仅对检索到的子图进行线性拼接或简单摘要，忽略了证据链的逻辑结构，同时引入大量冗余信息。本章提出一种结构引导的协同推理机制，使大语言模型能够在显式推理路径的约束下进行动态、渐进式推理，从而提升答案的准确性与连贯性。

在获得推理路径及其对应的文本证据后，本章首先对证据链进行结构化编排。具体而言，按照推理路径中短语结构三元组的顺序，对其对应的文本片段进行组织与拼接，从而构建逻辑连贯的上下文表示：

$$\mathcal{C} = \text{Concat}(s_{\tau_1}, s_{\tau_2}, \dots, s_{\tau_l}), \quad (3-23)$$

其中， $\mathcal{C}$ 表示最终构建的结构化上下文， $\text{Concat}(\cdot)$ 表示按推理顺序进行文本拼接的操作， s_{τ_i} 表示第 i 个短语结构三元组 τ_i 对应的文本证据片段， l 表示推理路径中包含的短语结构三元组总数。

与传统基于检索文档的 RAG 方法直接拼接完整检索文档不同，该过程将离散的结构化知识与非结构化文本信息进行融合，从而有效过滤冗余信息，使推理过程以自然语言形式呈现。该策略能够显著提升上下文的知识密度，降低无关信息的干扰，同时大幅减少输入大语言模型的提示词长度，从而为后续问答提供清晰且可追溯的证据支持。

3.4.3 最终答案生成

在构建完成提示后，输入大语言模型进行最终的答案生成。该过程包含以下两个阶段：

(1) 首先，大语言模型对当前证据进行充分性判断，即评估推理路径与文本证据是否能够完整回答用户问题。当证据充足时，模型基于结构化推理路径生成一个全面且符合逻辑的答案。

(2) 当模型判断当前证据不足以支持完整推理时，可以触发进一步的推理与探索过程（如扩展推理路径或补充证据）。在多轮推理仍未获得明确结论的情况下，模型将综合已有证据与其内在知识，生成最合理的答案。

上述机制实现了基于结构化证据的动态问答过程，有效提升了答案生成的准确性、连贯性与鲁棒性。

3.5 实验结果与分析

3.5.1 数据集

本章在三个典型的多跳问答基准数据集 MuSiQue^[55]、2WikiMultiHopQA^[56] 和 HotpotQA^[57] 上对方法进行评估，实验设置遵循 HippoRAG2^[41] 的配置，从每个数据集的验证集中随机采样 1000 条查询进行评估，所有查询均涉及多跳推理任务。

2WikiMultiHopQA: 2WikiMultiHopQA 是一个专门为多跳问答任务构建的数据集，旨在全面评估模型的多步推理能力。该数据集结合了结构化知识库 Wikidata 与非结构化文本 Wikipedia，通过自动构建生成高质量、自然流畅的问答对。数据集共包含约 192,606 个问答样本，其中训练集约 167,454 条，测试集约 25,152 条。问题类型覆盖比较型 (Comparative)、推理型 (Inferential)、组合型 (Compositional) 以及桥接型 (Bridge-comparison) 等多种多跳推理形式。

HotpotQA: HotpotQA 是一个大规模多跳问答数据集，旨在推动多跳推理与可解释问答系统的发展。该数据集包含约 112,779 条基于 Wikipedia 构建的问答对。其主要特点包括：一是问题通常需要跨多个文档进行信息检索与推理，从而有效评估模型的多跳推理能力；二是问题类型丰富，采用自然语言构建，不依赖于特定知识图谱结构；三是提供句子级支持事实标注，为评估模型的可解释性提供了重要依据。

MuSiQue: MuSiQue 数据集旨在解决现有多跳问答数据集中存在的“推理捷径”问题。该数据集采用自底向上的构建策略，通过组合多个单跳问题生成 2 至 4 跳的复杂问题。MuSiQue-Ans 版本包含约 248,814 条问答样本，其核心特点在于强

调“连贯推理”，即模型必须依赖前一步推理结果才能完成后续推理。该设计显著提高了任务难度，并有效抑制了模型通过单跳推理或捷径策略获得答案的可能性。

3.5.2 实验设置与评价指标

在超参数设置方面，本章采用基于检索文档构建小规模图的 RAG 方法^[32]中通常设置的检索规模，将检索文档数量设为 $\text{top-}k = 10$ ，候选短语结构三元组数量设为 $\text{top-}m = 20$ ，最大推理跳数设为 $D_{\max} = 4$ 。在推理路径构建过程中，采用 Beam Search 策略，束宽设置为 $B = 20$ ，并在每一步保留概率最高的前 $M = 5$ 个候选扩展路径。

在上下文证据构建方面，本章分别采用句子级与文档级两种粒度进行对比实验，对应方法记为 $\text{TTRAG}_{\text{sk+sens}}$ 和 $\text{TTRAG}_{\text{sk+docs}}$ ，其中“sk”表示推理路径（reasoning skeleton）。

在主实验中，所有方法均基于 GPT-4o-mini 和 Llama-3-8B-Instruct 两种大语言模型进行测试。本章采用多跳问答任务中常用的两种评价指标：精确匹配（Exact Match, EM）与 F1 分数（F1 Score）。

（1）EM：对于每个问题，EM 指标为二值指标。当模型预测答案与任一真实答案完全一致时，记为正确，否则为错误。设预测答案为 A_{pred} ，真实答案集合为 $\mathcal{A}_{\text{true}}$ ，则单个样本的 EM 计算如下：

$$\text{EM} = \mathbb{I}(A_{\text{pred}} \in \mathcal{A}_{\text{true}}), \quad (3-24)$$

其中，EM 表示精确匹配分数， $\mathbb{I}(\cdot)$ 为指示函数，当条件成立时取值为 1，否则为 0。最终 EM 分数为所有样本的平均值。

（2）F1：F1 分数用于衡量预测答案与真实答案之间的词级重叠程度，将答案视为词集合进行计算。相较于 EM 指标，F1 更为宽松。设预测答案为 A_{pred} ，真实答案为 A_{true} ，则精确率（Precision）与召回率（Recall）定义为：

$$\text{Precision} = \frac{|\text{words}(A_{\text{pred}}) \cap \text{words}(A_{\text{true}})|}{|\text{words}(A_{\text{pred}})|}, \quad (3-25)$$

其中，Precision 表示预测答案中正确词项所占比例， $\text{words}(\cdot)$ 表示将答案拆分为词集合的操作。

$$\text{Recall} = \frac{|\text{words}(A_{\text{pred}}) \cap \text{words}(A_{\text{true}})|}{|\text{words}(A_{\text{true}})|}, \quad (3-26)$$

其中，Recall 表示真实答案中被成功预测出的词项比例。

基于上述定义，F1 分数计算为：

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}, \quad (3-27)$$

其中，F1 表示精确率与召回率的调和平均值，用于综合衡量答案预测质量。

当一个问题对应多个真实答案时，取预测答案与所有真实答案计算得到的 F1 分数中的最大值作为该问题的最终得分。整体 F1 分数为所有问题得分的平均值。

3.5.3 基线模型

本章将所提出的 TTRAG 方法与多种具有代表性的 RAG 方法进行对比。这些基线方法涵盖了基于图结构的方法、层次化检索方法，以及不依赖外部知识的直接生成方法。

(1) None (Direct Generation, GPT-4o-mini): 以基础大语言模型作为对照，不引入任何检索或外部知识，直接根据输入问题生成答案。

(2) GraphRAG^[35]: 一种基于知识图谱的 RAG 框架，通过抽取实体与关系构建全局知识图谱，并结合查询导向摘要 (Query-Focused Summarization, QFS) 进行信息整合。该方法利用 Leiden 算法进行社区划分，对子图进行层次化总结，并在推理阶段通过映射与归约 (Mapping-Reduction) 机制生成最终答案。

(3) RAPTOR^[58]: 一种基于递归抽象的层次化检索方法，将长文本组织为树结构。该方法通过 SBERT 向量表示与高斯混合模型 (Gaussian Mixture Model, GMM) 对文本进行聚类，并在不同层级生成摘要。在检索阶段，自顶向下遍历相关节点，从而整合多层次上下文信息以支持复杂推理。

(4) LightRAG^[36]: 一种轻量级图结构 RAG 方法，结合图索引与双层检索机制。该方法利用大语言模型抽取实体与关系构建动态知识图谱，并通过底层实体查询与高层关系聚合实现高效检索，在保证推理能力的同时减少冗余信息。

(5) HippoRAG^[40]: 一种受海马体记忆机制启发的检索框架，将大语言模型与知识图谱及个性化 PageRank (Personalized PageRank) 相结合。该方法通过 OpenIE 构建开放领域知识图谱，并引入同义词边进行扩展，利用基于实体的 PageRank 算法实现多跳推理。

(6) HippoRAG2^[41]: HippoRAG 的改进版本，引入段落节点与 “contains” 关系以增强图结构表达能力，同时融合语义相似度与结构信息。在检索阶段，通过实体与短语联合初始化 PageRank，并结合大语言模型进行三元组过滤，从而提升事实推理与关系推理能力。

(7) KET-RAG^[37]: 一种低成本、多粒度图索引方法。该方法首先构建文本块的 KNN 图，并抽取实体关系三元组形成轻量级图推理路径。在检索阶段，将上下

文预算划分为图结构局部搜索与关键词检索两部分，从而在较低索引成本下实现高效检索。

3.5.4 性能实验结果与分析

主要实验结果如表3-1 和表3-2 所示。“AVG”表示 EM 与 F1 的平均值，“None”表示仅使用大语言模型直接生成答案（无检索）。每列最优结果以粗体标出，次优结果以下划线标出。本章分别在开源模型 Llama-3-8B-Instruct 和闭源模型 GPT-4o-mini 上对 TTRAG 方法进行评估，以下所有表未在表题中说明基座模型时，均为 GPT-4o-mini 的结果。并统计了各方法的性能指标及其 Token 消耗。

表 3-1 多跳问答基准数据集上的性能对比，基座模型为 GPT-4o-mini

Method	Musique			2WikiMultiHopQA			HotpotQA			Average		
	EM	F1	Avg	EM	F1	Avg	EM	F1	Avg	EM	F1	Avg
None	5.40	14.41	9.91	23.20	30.55	26.88	24.30	35.30	29.80	17.63	26.75	22.19
RAPTOR	27.70	39.20	33.45	39.70	48.40	44.05	50.60	64.70	57.65	39.33	50.77	45.05
GraphRAG	27.00	39.20	33.10	45.70	61.00	53.35	51.40	67.60	59.50	41.37	55.93	48.65
LightRAG	2.00	42.00	22.00	2.50	12.10	7.30	9.90	20.20	15.05	4.80	24.77	14.78
HippoRAG	19.20	29.80	24.50	46.60	59.50	53.05	41.80	55.00	48.40	35.90	48.10	42.00
HippoRAG2	32.60	<u>45.94</u>	<u>39.27</u>	52.40	61.33	56.87	58.10	72.59	65.35	47.70	59.95	53.83
KETRAG-P	12.40	17.05	14.73	28.50	34.95	31.73	42.60	55.88	49.24	27.83	35.96	31.90
TTRAG _{sk+docs}	32.50	46.11	39.31	55.20	65.09	60.15	58.40	<u>73.92</u>	<u>66.16</u>	<u>48.70</u>	61.71	55.20
TTRAG _{sk+sens}	<u>32.50</u>	45.32	38.91	<u>54.90</u>	<u>64.24</u>	<u>59.57</u>	<u>59.00</u>	74.36	66.68	48.80	<u>61.31</u>	<u>55.05</u>

表 3-2 多跳问答基准数据集上的性能对比，基座模型为 Llama-3-8B-Instruct

Method	Musique			2WikiMultiHopQA			HotpotQA			Average		
	EM	F1	Avg	EM	F1	Avg	EM	F1	Avg	EM	F1	Avg
HippoRAG	13.00	21.93	17.47	40.70	50.02	45.36	38.40	50.95	44.68	30.70	40.97	35.83
HippoRAG2	21.60	31.53	26.57	23.60	45.61	34.61	49.00	62.84	55.92	31.40	46.66	39.03
TTRAG _{sk+docs}	<u>19.30</u>	<u>27.46</u>	<u>23.38</u>	45.10	58.12	51.61	<u>49.80</u>	<u>63.08</u>	<u>56.44</u>	<u>38.07</u>	<u>49.55</u>	<u>43.81</u>
TTRAG _{sk+sens}	19.40	27.27	23.34	49.60	60.27	54.94	50.50	63.71	57.11	39.83	50.42	45.13

（1）问答性能分析（QA Performance）：实验结果表明，本章提出的 TTRAG 方法在多个基准数据集上均显著优于现有方法。在使用 GPT-4o-mini 时，TTRAG 的两个变体 TTRAG_{sk+docs} 和 TTRAG_{sk+sens} 均取得了最优或接近最优的整体表现。其中，TTRAG_{sk+sens} 在平均 EM 指标上取得最高值 48.80%，TTRAG_{sk+docs} 在平均 F1 指标以及平均 Avg 指标上表现最佳，分别达到 61.71% 和 55.20%。

在开源模型 Llama-3-8B-Instruct 上，TTRAG_{sk+sens} 在 2WikiMultiHopQA 和 HotpotQA 数据集上均取得最佳表现，并获得最高的整体平均分。这表明本章方法能够有效构建结构化知识表示，从而显著提升大语言模型在复杂多跳推理任务中的理解与问答能力。

(2) TTRAG 变体对比分析: TTRAG 的两种变体 $TTRAG_{sk+docs}$ 与 $TTRAG_{sk+sens}$ 在不同模型上的表现差异, 主要取决于大语言模型的能力水平。这两种方法的核心区别在于上下文粒度: 前者采用文档级证据, 提供更丰富的上下文信息, 但同时会引入更多噪声; 后者采用句子级证据, 通过更精细的筛选从而降低上下文的噪声, 并提高 Token 利用效率。

对于能力较强的 GPT-4o-mini, $TTRAG_{sk+docs}$ 在整体平均表现上略优, 其 Avg 分数为 55.20%, 而 $TTRAG_{sk+sens}$ 为 55.05%。且 $TTRAG_{sk+docs}$ 在更复杂的多跳任务 (如 MuSiQue) 上表现更佳。这说明高性能模型能够有效利用完整文档中的丰富信息进行复杂推理。

相比之下, 在能力较弱的 Llama-3-8B-Instruct 上, $TTRAG_{sk+sens}$ 表现明显更优, 其平均分显著高于 $TTRAG_{sk+docs}$, 提升 1.32%。这表明对于较小模型而言, 经过筛选的句子级上下文能够有效降低噪声干扰, 从而提升模型有限推理能力的利用效率。

因此, 对于高性能大语言模型, 文档级上下文有助于提供更完整的信息; 而对于能力受限的模型, 句子级上下文更有利于提升性能。这进一步验证了本章方法在不同模型场景下的适用性与灵活性。




图 3-7 TTRAG 与 HippoRAG2 在 Token 使用量与 EM 指标上的对比

(3) Token 消耗分析 (Token Cost): 如图3-7 所示, 柱状图表示 Token 数量, 折线表示 EM 分数。本章方法在显著提升性能的同时, 有效降低了 Token 消耗。相较

于表现较优的基线方法 HippoRAG2, TTRAG 在保持甚至提升问答性能的情况下, 将平均输入 Token 长度减少约 80%。

结果表明, 基于推理路径与短语结构三元组引导的文本选择策略, 能够在保证关键信息完整性的同时, 有效压缩上下文长度, 从而实现更高效的知识表示与推理过程。

3.5.5 消融实验结果与分析

为验证本章方法各组成模块的有效性, 本章对 TTRAG 的不同组件进行消融实验, 结果如表3-3 所示, “†”表示按照 HippoRAG2 设置, 采用 CoT 和少刺激提示来引出 LLM 的内部知识。“tris+alldocs”表示结合使用推理路径与所有检索到的文档。实验结果表明, 将推理路径(sk)与检索上下文(docs 或 sens)相结合能够显著提升模型性能, 验证了本章方法在结构化推理与文本证据融合方面的有效性。

表 3-3 对 TTRAG 的不同设置进行消融研究

Method	Musique		2Wiki		HotpotQA		Average	
	EM	F1	EM	F1	EM	F1	EM	F1
TTRAG _{sk}	29.90	44.68	51.80	62.37	56.10	70.59	45.93	59.21
TTRAG _{docs}	31.90	44.77	53.30	64.07	56.60	71.14	47.27	59.99
TTRAG _{sk+docs}	32.50	46.11	55.20	65.09	58.40	73.92	48.70	61.71
TTRAG _{sk+sens}	32.50	45.32	54.90	64.24	59.00	74.36	48.80	61.31
TTRAG _{sk+alldocs} [†]	39.00	52.56	63.50	72.13	61.00	75.94	54.50	66.88

具体而言, 仅使用推理路径的 TTRAG_{sk} 平均 EM 为 45.93%, 而仅使用文档检索的 TTRAG_{docs} 平均 EM 为 47.27%。当两者结合时, 性能显著提升, TTRAG_{sk+docs} 的平均 EM 达到 48.70%, 体现出明显的协同增益。

进一步地, 采用句子级上下文的 TTRAG_{sk+sens} 表现更加优越, 其平均 EM 为 48.33%, F1 达到 61.31%。这表明, 相较于直接使用完整文档, 经过筛选的高质量句子级上下文能够提供更高的知识密度, 从而提升模型性能。

此外, 本章参考 HippoRAG2 中的 few-shot 提示策略, 并将其与本章方法结合, 进一步提升了模型表现。实验结果显示, 在引入 CoT (Chain-of-Thought) 与 few-shot 提示后, TTRAG_{sk+alldocs} 的平均 EM 提升至 54.50%, F1 达到 66.88%, 取得显著提升。这一结果表明, 本章方法与提示工程策略具有良好的兼容性, 能够进一步激发大语言模型的推理能力。

(1) 上下文组织方式影响分析: 为探究上下文组织方式对模型性能的影响, 本章设计了两种新的上下文排列方式。第一种方法 TTRAG_{sk+sens+alt} 采用短语结构三

元组与对应文本句子交替排列的方式；第二种方法 $\text{TTRAG}_{\text{sk+sens+contain}}$ 在短语结构三元组与文本基础上进一步引入显式的“包含关系”标注。

如表3-4 所示，其中，“sk+sens+alt”表示短语结构三元组及其对应句子的交替排列，“sk+sens+contain”表示在短语结构三元组和句子之后附加包含关系。在 Llama-3-8B-Instruct 模型上的实验结果表明，这些结构化调整在部分数据集上能够带来一定性能提升。例如，在 HotpotQA 数据集上，两种方法均取得较好效果。然而，在更具挑战性的多跳推理数据集（如 MuSiQue）上，这两种方法的表现均明显下降。这表明，仅通过调整上下文顺序或增加结构标注，难以从根本上解决复杂推理场景中的性能瓶颈问题。

表 3-4 Llama-3-8B-Instruct 中不同上下文顺序的性能表现

Method	Musique		2Wiki		HotpotQA		Average	
	EM	F1	EM	F1	EM	F1	EM	F1
$\text{TTRAG}_{\text{sk+sens}}$	19.40	27.27	49.60	60.27	50.50	63.71	39.83	50.42
$\text{TTRAG}_{\text{sk+sens+alt}}$	18.70	26.62	45.60	57.22	50.80	63.92	38.37	49.25
$\text{TTRAG}_{\text{sk+sens+contain}}$	18.70	26.61	48.20	58.67	50.00	64.40	38.97	49.89

综上所述，上下文结构优化虽能在一定程度上改善模型表现，但其效果依赖于任务复杂度。对于复杂多跳推理任务，仍需依赖更强的结构化推理机制与高质量证据筛选策略。

（2）Zero-shot 设置与提示设计分析：在本章实验中，我们采用 zero-shot 设置，并明确约束大语言模型仅基于给定上下文生成答案。该设计旨在尽可能隔离模型参数知识的影响，从而更加公平地评估检索信息在 RAG 框架中的实际贡献。

这一设置与 HippoRAG2 所采用的提示策略有所不同。HippoRAG2 结合了提示工程 COT 与 few-shot 提示策略，这种方式容易引导模型生成隐式推理链，并更多依赖其参数化知识。在这种情况下，纯文本上下文通常更容易受益于该提示形式，而结构化的短语结构三元组输入则难以充分发挥其优势，从而影响对不同检索方式的公平比较。

如表3-1 与表3-5 的对比所示，HippoRAG2 在不同数据集上的性能均受到一定程度的影响，其中在 2WikiMultiHopQA 上的性能下降尤为明显。这进一步表明，在依赖 COT 与 few-shot 提示策略的设置下，模型更倾向于利用内部知识而非外部检索信息。因此，本章采用严格的 zero-shot 与基于上下文约束的生成方式，以确保不同方法之间的对比更加公平和可解释。

如表3-5所示，“tris+alldocs”表示结合使用推理路径与所有检索到的文档。在引入 CoT 与 few-shot 提示策略的设置下， $\text{TTRAG}_{\text{tris+alldocs}}$ 取得了最优整体性能。这

表 3-5 采用 HippoRAG2 COT+few-shot 提示策略的实验结果

Method	Musique		2Wiki		HotpotQA		Average	
	EM	F1	EM	F1	EM	F1	EM	F1
HippoRAG2	<u>36.20</u>	<u>50.92</u>	<u>62.00</u>	72.51	<u>58.50</u>	<u>73.35</u>	<u>52.23</u>	<u>65.59</u>
TTRAG _{tris}	29.90	44.68	51.80	62.37	56.10	70.59	45.93	59.21
TTRAG _{docs}	31.90	44.77	53.30	64.07	56.60	71.14	47.27	59.99
TTRAG _{tris+docs}	33.00	46.45	54.60	65.59	56.80	71.48	48.13	61.17
TTRAG _{tris+sens}	33.90	46.87	54.10	64.62	57.00	71.83	48.33	61.11
TTRAG _{tris+alldocs}	39.00	52.56	63.50	<u>72.13</u>	61.00	75.94	54.50	66.88

表明 Thought 与 few-shot 提示在纯文本上下文场景中具有更强的性能提升作用。然而，即便在该设置下，引入 TTRAG 构建的短语结构三元组推理路径仍然能够在多个多跳问答基准上带来稳定的性能提升，验证了结构化推理信息的有效性。

此外，表3-6 对采用 HippoRAG2 COT+few-shot 提示策略时，不同设置下的输入 Token 长度进行了分析。结果表明，在引入短语结构三元组推理路径后，TTRAG_{tris+alldocs} 的输入长度仅有小幅增加，但却带来了显著的性能提升。这说明基于短语结构三元组的结构化推理路径是一种高效的上下文压缩与知识表达方式，能够在控制计算成本的同时有效增强模型的多跳推理能力。

表 3-6 采用 HippoRAG2 COT+few-shot 提示策略时，不同设置下输入 token 长度的对比

Method	Musique	2WikiMultiHopQA	HotpotQA	Average
HippoRAG2	2,100	2,343	2,004	2,149
TTRAG _{tris}	95	89	90	91
TTRAG _{docs}	307	386	232	308
TTRAG _{tris+docs}	345	423	266	345
TTRAG _{tris+sens}	<u>199</u>	<u>187</u>	<u>169</u>	<u>185</u>
TTRAG _{tris+alldocs}	2,219	2,440	2,103	2,254

3.5.6 样例分析

如图 3-8 所示，传统基于文本的 RAG 方法在处理长上下文时，往往会引入大量无关信息，从而产生显著噪声，干扰大语言模型对关键信息的提取，进而影响最终问答结果的准确性。

相比之下，本章方法首先通过推理路径构建（Reasoning Skeleton Construction）提取关键短语结构三元组，形成清晰的推理路径；随后通过上下文证据索引（Contextual Evidence Index）筛选与短语结构三元组高度相关的文本证据，从而对结构化推理路径进行语义补充。这种“先构建结构、再补充语义”的两阶段过程，有效过滤了冗余信息并提升了知识密度，使得模型能够基于更精确、可控的上下文进




图 3-8 TTRAG 的可解释推理过程

行推理，从而显著提高问答准确性。同时，该过程提供了显式的推理路径，有助于提升模型决策过程的可解释性。

不同推理类型性能分析（Performance Breakdown）：为进一步分析本章方法在不同推理类型下的性能表现，本章在 2WikiMultiHopQA 数据集上对不同推理类型的问题进行了 win-loss 分析。




图 3-9 TTRAG 与 HippoRAG2 在 2WikiMultiHopQA 数据集不同推理类型上的胜负对比分析。

如图3-9所示，正值表示 TTRAG 回答正确而基线模型回答错误的样本，负值则表示相反的情况。相较于 HippoRAG2，本章方法在各类推理任务上均取得了整体性能提升。其中，在 Comparison 与 Compositional 问题上，性能提升最为显著。能够在各类推理类型上实现较为均衡且稳定的性能增强，并非仅针对某一特定推

理模式进行优化而牺牲其他类型任务表现，体现出更全面的多跳推理能力与良好的泛化性。上述结果从更细粒度角度揭示了模型在不同推理类型下的行为特征。

文本证据对结构信息缺失的补充作用：进一步分析 TTRAG 如何缓解自动知识抽取过程中三元组信息不完整对推理结果的影响,如图3-10 所示,对于问题:“*Where was the husband of Joanna Elisabeth Of Holstein-Gottorp born?*”, 仅使用短语结构三元组构建的推理路径进行回答时, 模型得到的上下文主要包含 “Joanna Elisabeth of Holstein-Gottorp place of birth Gottorp” 等事实。由于推理路径中缺少 Christian August 出生地点这一关键事实, 模型容易将与问题相关实体所在家族的出生地信息误认为目标答案, 最终错误地输出 “Gottorp”。




图 3-10 TTRAG 利用显式推理路径定位关键证据并补充缺失信息

而在 TTRAG 中, 通过基于结构化推理路径的上下文文本证据索引, 利用文本证据补充了结构信息中缺失的出生地点事实, 使模型能够依据完整证据链得到正确答案 “Dornburg”。该案例表明, 自动抽取的短语结构三元组虽然能够以紧凑形式提供推理线索, 但受开放式信息抽取质量限制, 仍可能存在关键事实遗漏的问题。TTRAG 所采用的 “结构引导 + 文本补充” 机制能够利用显式推理路径精确定位相关文本证据, 对结构信息中的缺失内容进行有效补充, 从而降低知识抽取误差对后续推理过程的影响, 提高复杂多跳问答任务中的推理可靠性与结果可解释性。

3.6 本章小结

本章针对传统 RAG 方法在多跳推理任务中存在的上下文噪声高、推理路径不清晰以及结构信息利用不足等问题, 提出了一种基于结构分析的检索增强生成方

法 (TTRAG)。具体而言, 本章首先通过检索器从语料库中获取与问题相关的候选文档, 并利用大语言模型执行开放式信息抽取, 构建文档级短语结构三元组图。在此基础上, 设计了基于向量检索与大语言模型引导的推理路径构建方法, 通过迭代式路径扩展与束搜索策略生成高质量的短语结构三元组推理路径。随后, 通过上下文证据索引机制, 将推理路径与原始文本进行精确对齐, 筛选出高相关的句子或文档级证据, 从而在保证语义完整性的同时有效降低上下文噪声。在提示构建阶段, TTRAG 将结构化的推理路径与对应文本证据进行有序编排, 形成高质量上下文输入, 引导大语言模型生成最终答案。该方法通过“结构引导 + 语义补充”的两阶段机制, 实现了结构化知识与非结构化文本的有效融合。最后, 通过在多个多跳问答数据集上的实验验证, TTRAG 方法在问答性能与计算效率方面均取得显著提升。消融实验与样例分析进一步表明, 推理路径与上下文筛选策略能够有效提高知识密度与推理可解释性。

第4章 基于结构与语义联合建模的检索增强生成方法

4.1 引言

近年来，检索增强生成通过引入外部知识，有效缓解了大语言模型在知识更新与事实准确性方面的局限。然而，在复杂多跳问答任务中，如何在保证检索精度的同时降低上下文噪声，并有效组织检索到的知识信息，仍然是当前研究面临的关键挑战

针对这一问题，基于知识图谱的 GraphRAG^[35] 方法通过显式建模实体及其关系，构建结构化知识以支持多跳推理。典型方法如 GraphRAG 通过社区划分与分层摘要实现由粗到细的检索过程，后续工作（如 GFM-RAG^[38]、GRetriever^[39] 与 LightRAG^[36]）进一步引入图神经网络、结构优化目标及多级索引机制，在一定程度上提升了推理能力与检索效率。此外，HippoRAG 及其改进版本 HippoRAG2 从认知机制出发，结合个性化 PageRank 实现多跳检索，增强了上下文建模能力。

然而，现有研究表明，GraphRAG 方法在实际应用中往往难以稳定优于传统 RAG。这一问题的根本原因在于自动构建知识图谱的质量难以保证：一方面，关系抽取过程存在误差，导致局部语义关系不准确；另一方面，缺乏全局一致性约束，使得图结构呈现碎片化特征。这些问题共同引入结构冲突与语义歧义，从而削弱检索结果的有效性。

为降低复杂关系建模带来的不稳定性，LinearRAG^[42] 提出以“线性图”为核心的轻量化建模方式，通过仅建模实体与文本之间的语义关联，实现无需复杂关系图构建的高效检索框架。该方法基于分层语义结构与两阶段检索机制，在多跳问答任务中取得了较好的性能与效率表现。

尽管 LinearRAG 在效率与鲁棒性方面具有一定优势，但其仍存在若干局限。首先，仅依赖实体级语义信息，难以覆盖更加丰富的语义表达内容，例如概念性短语与描述性语义；其次，段落表示通常基于整体编码，忽略了句子层级的重要性差异，限制了段落表示对局部关键信息的刻画能力；此外，其上下文构建仍主要依赖文本段落，缺乏对实体语义与短语结构关系的有效结合，从而限制了模型对复杂语义关联与多跳推理线索的利用能力。

为此，本章在短语结构三元组与文本片段的基础上，提出一种基于结构与语义联合建模的检索增强生成方法——Joint Semantic LinearRAG (JS-LinearRAG)。该方法从语义信息扩展、段落表示优化以及结构增强上下文构建三个方面对原有流程进行改进，主要包括以下三个部分：

(1) 语义信息抽取机制：在语义抽取阶段，引入实体语义信息抽取，用于补充文本中的关键语义概念；同时，从文本中抽取短语结构三元组，用于提供局部结构关系表达，从而增强上下文对复杂语义关系的表示能力；

(2) 基于句子加权的段落表示：在表示学习阶段，通过对句子嵌入进行加权聚合，刻画段落内部不同句子的语义重要性分布，从而提升段落表示的精细程度与语义表达能力；

(3) 结构增强的联合语义上下文构建：在上下文构建阶段，基于短语结构三元组、实体语义信息与文本段落，构建“结构 + 文本 + 语义”的联合增强上下文表示，在保持文本语义完整性的同时，增强上下文中的结构关联表达能力，从而提升模型的理解与推理能力。




图 4-1 四种 RAG 范式的对比分析

与第三章提出的基于结构分析的 TTRAG 方法相比，本章方法同样引入短语结构三元组信息，但二者的作用方式存在明显差异。第三章侧重于利用短语结构三元组构建显式结构化推理路径，通过逐步扩展推理路径实现对多跳证据的组织与筛选；而本章并不构建完整的推理路径，而是将短语结构三元组作为辅助结构表达，结合实体语义信息与文本段落，构建结构增强的联合语义上下文。因此，本章方法可以看作是在第三章结构分析思想基础上的轻量化扩展，在无需显式推理路径的情况下，通过结构关系表达与语义信息补充相结合，实现对检索内容的精细表达与高效利用，为轻量化检索增强生成框架下的多跳推理提供了一种新的实现思路。

本章组织结构如下：4.2 节介绍结构与语义联合信息抽取方法；4.3 节介绍基于句子加权的段落表示方法；4.4 节介绍结构增强的联合语义上下文构建方法；4.5 节介绍实验结果与分析；4.6 节为本章小结。

4.2 语义信息抽取

在原始 LinearRAG 中，语义建模主要依赖实体作为核心语义单元，通过实体与文本之间的关联构建线性语义结构。然而，仅依赖实体级语义信息往往难以充分表达复杂文本中的完整知识结构。在实际多跳问答任务中，除显式命名实体外，大量关键知识还以事实关系、属性描述以及概念性表达等形式存在。因此，仅使用实体级表示容易导致语义覆盖不足，从而限制检索系统对复杂问题的语义理解能力与推理能力。

与此同时，第三章研究表明，结构化信息能够有效提升上下文知识密度并降低上下文噪声。但显式结构分析方法通常依赖复杂关系建模与路径搜索，存在构建成本较高的问题。因此，如何在保持轻量化建模优势的同时，有效利用结构信息增强语义表达能力，成为当前检索增强生成中的关键问题。

为此，本文提出一种结构与语义联合信息抽取方法。该方法以短语结构三元组与文本片段为基础，进一步引入实体语义信息抽取机制，构建结构信息与语义信息协同增强的联合表示。其中，短语结构三元组主要用于提供轻量化结构关系表达，实体语义信息则用于增强语义覆盖范围，从而实现结构信息与语义信息的联合建模。

任务定义：给定检索得到的文档集合：

$$\mathcal{D}_k = \{d_1, d_2, \dots, d_k\}, \quad (4-1)$$

其中， k 表示检索文档数量，每个文档 d_i 包含若干文本句子。

本文目标是从文档集合中抽取联合结构与语义信息集合 $\mathcal{U}$ ，包括短语结构三元组集合 $\mathcal{T}$ 与实体语义集合 $\mathcal{E}$ ：

$$\mathcal{U} = \mathcal{T} \cup \mathcal{E}, \quad (4-2)$$

其中， $\mathcal{T}$ 表示短语结构三元组集合，用于提供辅助结构关系信息； $\mathcal{E}$ 表示实体语义集合，用于增强文本语义覆盖能力。

通过联合建模结构信息与语义信息，本文旨在同时提升上下文知识密度、语义表达能力与复杂推理能力。

4.2.1 短语结构三元组抽取

为增强文本中的结构表达能力，本文首先基于开放式信息抽取方法，从检索文档中抽取短语结构三元组：

$$\mathcal{T}_i = g(d_i), \quad (4-3)$$

其中， $g(\cdot)$ 表示基于大语言模型提示的短语结构三元组抽取函数， $\mathcal{T}_i$ 表示从文档 d_i 中抽取得到的短语结构三元组集合。

每个短语结构三元组可表示为：

$$\tau = (h, r, t), \quad (4-4)$$

其中， h 表示头实体或主题短语， r 表示语义关系， t 表示尾实体、属性或事实描述。

与第三章不同，本章中的短语结构三元组并不用于构建显式推理路径或复杂路径搜索，而是作为联合语义建模中的辅助结构信息，用于补充文本中的局部关系表达，提升整体知识表示的结构完整性。

最终，全局短语结构三元组集合定义为：

$$\mathcal{T} = \bigcup_{i=1}^k \mathcal{T}_i, \quad (4-5)$$

4.2.2 实体语义信息抽取

在结构信息基础上，本文进一步引入实体语义信息抽取机制，用于增强文本中的语义覆盖能力。

对于每个文档 $d_i \in \mathcal{D}_k$ ，采用命名实体识别模型抽取实体集合：

$$\mathcal{E}_i = \text{NER}(d_i), \quad (4-6)$$

其中， $\text{NER}(\cdot)$ 表示实体识别函数， $\mathcal{E}_i$ 表示从文档 d_i 中抽取得到的实体集合。

为提升语义质量，本文过滤数值类、序数类等弱语义实体，仅保留具有实际知识意义的实体节点。

最终，全局实体语义集合定义为：

$$\mathcal{E} = \bigcup_{i=1}^k \mathcal{E}_i, \quad (4-7)$$

实体语义信息能够为后续语义匹配与上下文构建提供关键语义锚点，增强模型对复杂问题中核心语义概念的表达能力。

4.2.3 联合结构与语义信息组织

在获得短语结构三元组集合 $\mathcal{T}$ 与实体语义集合 $\mathcal{E}$ 后, 本文进一步构建联合结构与语义信息集合:

$$\mathcal{U} = \{u_1, u_2, \dots, u_n\}, \quad u_i \in \mathcal{T} \cup \mathcal{E}, \quad (4-8)$$

其中, n 表示联合结构与语义信息单元总数。

随后, 本文对联合信息进行统一组织与筛选, 包括删除重复信息单元、过滤低信息量结构关系、保留与查询相关性较高的结构与语义信息等, 从而形成兼具结构表达能力与语义覆盖能力的联合表示。短语结构三元组能够补充文本中的局部关系表达, 提升知识组织能力, 实现结构信息增强; 实体语义信息能够增强文本中的核心语义表达能力, 实现语义覆盖增强; 联合建模结构信息与语义信息, 能够进一步提升上下文知识密度与语义完整性, 实现结构语义协同增强; 更加丰富的结构与语义信息有助于提升 RAG 方法在复杂多跳问答任务中的检索与推理能力。

4.3 基于句子加权的段落表示方法

在传统的检索增强生成方法中, 段落通常通过整体编码或简单平均池化 (mean pooling) 的方式进行表示。然而, 这种方式忽略了段落内部句子在语义表达上的差异性, 使得重要信息可能被稀释, 从而影响检索精度与后续推理效果。

为此, 本章提出一种基于句子加权的段落表示方法, 通过在句子层面对语义信息进行建模, 并基于句子重要性进行加权聚合, 从而获得更加精细的段落表示。

给定文档集合 $\mathcal{D}_k$, 每个文档 d_i 由若干句子组成:

$$d_i = \{s_{i1}, s_{i2}, \dots, s_{in_i}\}, \quad (4-9)$$

其中, s_{ij} 表示文档 d_i 中的第 j 个句子, n_i 表示句子数量。本章的目标是构建段落表示向量 $\mathbf{e}_{d_i}$, 使其能够更准确地反映段落的语义结构。

4.3.1 句子级语义表示

首先, 对每个句子进行编码, 得到其向量表示:

$$\mathbf{e}_{s_{ij}} = \text{Encoder}(s_{ij}), \quad (4-10)$$

其中, $\mathbf{e}_{s_{ij}}$ 表示文档 d_i 中第 j 个句子 s_{ij} 的语义向量表示, $\text{Encoder}(\cdot)$ 表示文本编码模型 (如 E5、BGE^[59] 等)。相比直接对整个段落编码, 句子级编码能够保留更细粒度的语义信息。

4.3.2 句子权重建模

考虑到不同句子在段落中的信息量存在差异，较长的句子通常包含更多语义信息，因此在段落表示中应赋予更高权重。本章采用基于句子长度的权重分配策略。具体地，将句子的词数作为其重要性度量：

$$w_{ij} = \frac{|s_{ij}|}{\sum_{k=1}^{n_i} |s_{ik}|}, \quad (4-11)$$

其中， $|s_{ij}|$ 表示句子 s_{ij} 的词数， w_{ij} 表示句子 s_{ij} 在段落 d_i 中的归一化权重， n_i 表示文档 d_i 中的句子总数。

4.3.3 段落表示构建

在获得句子表示与对应权重后，本章通过加权聚合的方式构建段落表示：

$$\mathbf{e}_{d_i} = \sum_{j=1}^{n_i} w_{ij} \cdot \mathbf{e}_{s_{ij}}, \quad (4-12)$$

其中， $\mathbf{e}_{d_i}$ 表示文档 d_i 的最终段落向量表示， w_{ij} 表示句子权重， $\mathbf{e}_{s_{ij}}$ 表示对应句子的语义向量。

该表示方式能够根据句子的重要性对语义进行重构，从而避免简单平均带来的信息稀释问题。

与传统的段落表示方法相比，本章提出的句子加权方法通过句子级编码保留段落内部的语义结构，并基于句子长度分配权重，使得关键信息能够获得更高的贡献，同时减少无关或冗余句子对整体表示的干扰。

此外，基于句子加权的段落表示方法无需引入额外训练参数，计算开销较低，易于集成到现有检索框架中。基于句子加权的段落表示方法能够在保证效率的前提下显著提升语义表示质量，为结构增强的联合语义上下文构建提供更精准的向量检索基础。

4.4 结构增强的联合语义上下文构建方法

在完成语义信息抽取（第 4.2 节）与基于句子加权的段落表示（第 4.3 节）后，如何将结构信息、文本信息与语义信息进行有效融合，构建高质量增强上下文，是影响检索增强生成性能的关键因素。

传统 RAG 方法通常仅使用段落级文本作为上下文。LinearRAG 虽然引入实体信息，但其上下文仍主要依赖文本片段，缺乏对结构信息、文本证据与语义信息的统一组织。这种上下文构建方式在复杂多跳问答任务中容易受到冗余文本干扰，也难以充分表达潜在的结构关系与关键语义线索。

为此，本章提出一种结构增强的联合语义上下文构建方法。该方法在短语结构三元组和文本片段的基础上，进一步融合实体语义信息，构建“结构 + 文本 + 语义”的联合增强上下文表示。其中，短语结构三元组用于提供辅助结构关系，文本片段用于提供原始上下文证据，实体信息用于增强语义覆盖范围。通过上述信息的协同组织，模型能够在较低上下文成本下获得更高的信息密度与更清晰的推理线索。本章方法在设计思想上受到第三章 TTRAG 方法的启发。TTRAG 通过构建显式的短语结构三元组推理路径，并结合文本证据进行上下文证据索引，实现了结构化信息与非结构化文本的有效融合。与之不同，本章并不显式构建完整推理路径，而是将短语结构三元组作为辅助结构信息整合进联合语义上下文中，通过短语结构三元组、文本片段与实体语义信息的协同组织，在隐式语义空间中引导模型完成推理。因此，本章方法可以看作是在第三章结构分析思想基础上的轻量化扩展，在降低结构推理构建成本的同时，保留一定的结构增强能力。

4.4.1 结构与语义信息检索

基于第 4.2 节构建的联合结构与语义信息集合 $\mathcal{U} = \mathcal{T} \cup \mathcal{E}$ 以及候选段落集合 $\mathcal{D}_k$ ，本文首先分别检索与查询 q 相关的结构信息、语义信息和文本信息。

对于联合结构与语义信息集合 $\mathcal{U}$ ，其相关信息检索过程定义为：

$$\mathcal{U}_q = \text{TopK}(\text{Sim}(q, \mathcal{U})), \quad (4-13)$$

其中， $\mathcal{U}_q$ 表示与查询 q 最相关的前 K 个结构与语义信息单元集合， $\text{Sim}(\cdot)$ 表示基于向量表示的相似度函数， $\text{TopK}(\cdot)$ 表示选取相似度最高的前 K 个结果。

由于 $\mathcal{U}$ 由短语结构三元组集合 $\mathcal{T}$ 与实体语义集合 $\mathcal{E}$ 组成，因此检索结果可进一步划分为：

$$\mathcal{U}_q = \mathcal{T}_q \cup \mathcal{E}_q, \quad (4-14)$$

其中， $\mathcal{T}_q$ 表示与查询相关的短语结构三元组集合， $\mathcal{E}_q$ 表示与查询相关的实体语义集合。

进一步地，基于第 4.3 节得到的段落表示，对候选段落集合 $\mathcal{D}_k$ 进行文本片段检索：

$$\mathcal{D}_q = \text{TopK}(\text{Sim}(q, \mathcal{D}_k)), \quad (4-15)$$

其中， $\mathcal{D}_q$ 表示与查询 q 最相关的前 K 个文本片段集合。

通过上述检索过程，本文分别获得与问题相关的结构关系信息、实体语义信息和文本证据信息。

4.4.2 结构增强的联合上下文构建

在获得相关短语结构三元组集合 $\mathcal{T}_q$ 、实体语义集合 $\mathcal{E}_q$ 与文本片段集合 $\mathcal{D}_q$ 后，本文将三类信息进行统一组织，构建最终的结构增强联合语义上下文：

$$C_q = \mathcal{T}_q \oplus \mathcal{D}_q \oplus \mathcal{E}_q, \quad (4-16)$$

其中， C_q 表示最终输入大语言模型的查询上下文， $\oplus$ 表示上下文融合操作。

具体而言，联合增强上下文由结构信息、文本信息与语义信息三部分组成。短语结构三元组作为结构信息，用于提供简洁的关系线索；文本片段作为原始证据，用于补充完整语义背景；实体信息作为语义信息，用于突出问题相关的核心语义节点。三者共同构成“结构 + 文本 + 语义”的增强上下文表示。

为进一步提升上下文组织质量，本文采用层级化排列方式，将不同类型的信息按照“结构关系—文本证据—语义线索”的顺序进行组织：

$$C_q = \text{Concat}(\mathcal{T}_q, \mathcal{D}_q, \mathcal{E}_q), \quad (4-17)$$

其中， $\text{Concat}(\cdot)$ 表示上下文拼接函数。

该组织方式具有明确的作用分工：首先，短语结构三元组为大语言模型提供紧凑的结构化关系提示；其次，文本片段提供可追溯的原始上下文证据；最后，实体语义信息补充关键语义节点，帮助模型更好地聚焦问题相关对象。通过这种层级化组织方式，大语言模型能够先获得结构线索，再结合文本证据与语义信息进行综合推理。

如图4-2所示，结构增强的联合语义上下文通过多类型信息组织，为大语言模型提供高密度且结构清晰的输入，从而提升推理能力与答案准确性。首先，短语结构三元组能够以较少 Token 开销提供结构化关系线索，从而提升上下文的信息密度；其次，文本片段保留了原始语义证据，能够缓解单纯结构表示语义不足的问题；最后，实体语义信息能够突出核心语义对象，增强模型对问题关键对象的识别与理解能力。因此，“结构 + 文本 + 语义”的联合增强上下文能够在保持较低构建成本的同时，提升大语言模型对复杂多跳问题的理解与推理能力。

与第三章 TTRAG 方法相比，本章方法不依赖显式构建的完整推理路径，而是通过结构信息、文本信息与语义信息的联合建模，引导模型在隐式语义空间中完成推理。这种方式在保持较低构建成本的同时，提供了更加灵活的上下文表达形式。因此，结构增强联合语义上下文构建方法实现了从“单一语义表示”向“结构与语义联合建模”的转变，为提升 RAG 在复杂问答任务中的性能提供了关键支持。

结构增强联合语义上下文提示模板

作为一名高级阅读理解助手，你的任务是仔细分析文本段落和相应的问题。你的回答应从“思考：”之后开始，在此部分，你需要系统地阐述你的推理过程，说明你是如何得出结论的。最后，以“答案：”结尾，给出简洁明了、明确的回答，无需赘述。

短语结构三元组: {Retrieved Phrase-Structured Triples}

文本段落: {Retrieved Paragraphs}

实体: {Retrieved Entities}

问题: {Question}

思考:

图 4-2 结构增强联合语义上下文提示模板

4.5 实验结果及分析

4.5.1 数据集

本章在三个典型的多跳问答基准数据集上对所提出方法进行评估，包括 MuSiQue、2WikiMultiHopQA 和 HotpotQA。实验设置遵循 HippoRAG2 的配置，从每个数据集的验证集中随机采样 1000 条查询进行评估，所有查询均涉及多跳推理任务。

4.5.2 实验设置及评价指标

在实现方面，本文采用 spaCy 作为实体抽取工具，编码模型选用 all-mpnet-base-v2，用于生成语义向量表示。短语结构三元组抽取与最终回答由大语言模型 GPT-4o-mini 或 Llama-3-8B-Instruct 生成。在超参数设置方面，本章采用多数 RAG 基线方法^[40-42] 通常设置的检索规模，将检索文档数量设为 $\text{top-}k = 5$ 。

本章采用两个指标对方法进行评估：Contain-Acc.（包含匹配准确率）和 GPT-Acc.（基于大语言模型的评估准确率）。

（1）Contain-Acc.：用于衡量生成答案是否包含标准答案，是一种宽松匹配指标。对于给定问题，若预测答案 A_{pred} 中包含任一标准答案 A_{true} ，则视为预测正确。其定义如下：

$$\text{Contain-Acc.} = \mathbb{I}(A_{true} \subseteq A_{pred}), \quad (4-18)$$

其中，Contain-Acc. 表示包含准确率指标， $\mathbb{I}(\cdot)$ 为指示函数，当条件成立时取值为 1，否则为 0。最终结果为所有样本上的平均值。

（2）GPT-Acc.：是一种基于大语言模型的评估指标，用于衡量预测答案与标准

答案在语义层面的匹配程度。具体而言，采用 GPT-4o-mini 或 Llama3-8B-Instruct 作为评估器，对预测答案 A_{pred} 与标准答案 A_{true} 进行比较，并输出判断结果：

$$\text{GPT-Acc.} = \frac{1}{N} \sum_{i=1}^N \text{LLM-Eval}(A_{pred}^{(i)}, A_{true}^{(i)}), \quad (4-19)$$

其中，GPT-Acc. 表示基于大语言模型的准确率指标，LLM-Eval($\cdot$) 表示由大语言模型返回的二值判断结果（匹配为 1，不匹配为 0）， N 为测试样本数量， $A_{pred}^{(i)}$ 与 $A_{true}^{(i)}$ 分别表示第 i 个测试样本的预测答案与标准答案。

相比于 Contain-Acc.，GPT-Acc. 能够更好地评估语义一致性，尤其适用于表达方式不完全一致但语义等价的情况。

4.5.3 基线模型

本章将所提出的 JS-LinearRAG 方法与多种具有代表性的 RAG 方法进行对比，这些方法覆盖了从传统密集检索到图结构增强检索的不同技术路线。

(1) Dense Retrieval (Naive RAG): 基于向量相似度的经典检索增强生成方法。该方法直接将查询与文档编码为向量，通过相似度检索相关文本，并将其拼接作为上下文输入大语言模型进行回答，不涉及结构化建模。

(2) LightRAG^[36]: 一种轻量级图结构 RAG。

(3) HippoRAG^[40]: 受人类记忆机制启发的检索框架，将非结构化文本转化为知识图谱，并通过个性化 PageRank 算法进行多跳检索。

(4) GFM-RAG^[38]: 一种基于图结构优化的 RAG 方法，通过引入图神经网络与结构约束，对检索过程进行建模与优化，从而提升多跳推理的准确性与泛化能力。

(5) HippoRAG2^[41]: 在 HippoRAG 原有图结构基础上引入段落节点及“包含关系”边，同时融合语义相似度与结构信息进行联合检索。

4.5.4 性能实验结果及分析

主要实验结果如表 4-1 和表 4-2 所示。本文在三个典型多跳问答数据集 (MuSiQue、2WikiMultiHopQA 和 HotpotQA) 上，系统比较了所提出的 JS-LinearRAG 及短语结构三元组结构增强的 JS-LinearRAG_{pst} 与多种主流 RAG 方法的性能表现。其中，“C-Acc.”表示 Contain-Acc.，“G-Acc.”表示 GPT-Acc.，“Avg”表示两项指标的平均值。同时，表格最后一列统计了三个数据集上的整体平均性能，以综合评估各方法的总体效果。为更系统分析结构分析与语义分析两类技术路径的关系，本文补充了第三章 TTRAG 在联合语义增强条件下的变体 (TTRAG_{sk+docs+se}、

TTRAG_{sk+sens+se}), 从而能够更全面评估短语结构三元组结构信息与联合语义信息在不同方法范式中的作用差异。本章分别在开源模型 Llama-3-8B-Instruct 和闭源模型 GPT-4o-mini 上进行评估, 以下所有表未在表题中说明基座模型时, 均为 GPT-4o-mini 的结果。

表 4-1 在三个多跳问答数据集上的性能对比, 基座模型为 GPT-4o-mini

Method	MuSiQue			2WikiMultiHopQA			HotpotQA			Average		
	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg
DenseRetrieval	25.90	29.10	27.50	43.80	38.60	41.20	52.90	54.80	53.85	40.87	40.83	40.85
LightTRAG	27.40	28.60	28.00	55.20	39.00	47.10	60.30	59.50	59.90	47.63	42.37	45.00
HippoRAG	29.30	24.10	26.70	66.10	59.90	63.00	57.00	59.30	58.15	50.80	47.77	49.28
GFM-RAG	29.90	34.60	32.25	66.80	59.60	63.20	62.70	65.60	64.15	53.13	53.27	53.20
HippoRAG2	31.00	35.00	33.00	62.70	55.00	58.85	62.90	64.30	63.60	52.20	51.43	51.82
LinearRAG	31.50	34.90	33.20	<u>69.80</u>	64.20	67.00	67.00	66.90	66.95	56.10	55.33	55.72
TTRAG _{sk+docs}	29.90	41.10	35.50	68.90	59.30	64.10	<u>71.40</u>	70.90	<u>71.15</u>	56.73	57.10	56.92
TTRAG _{sk+sens}	29.20	<u>40.70</u>	34.95	66.90	56.60	61.75	<u>71.40</u>	70.90	<u>71.15</u>	55.83	56.07	55.95
TTRAG _{sk+docs+se}	28.20	39.60	33.90	65.10	57.10	61.10	72.10	<u>70.50</u>	71.30	55.13	55.73	55.43
TTRAG _{sk+sens+se}	28.20	38.40	33.30	63.80	56.40	60.10	70.60	69.20	69.90	54.20	54.67	54.43
JS-LinearRAG	<u>35.20</u>	40.30	<u>37.75</u>	70.00	<u>64.00</u>	67.00	70.50	69.50	70.00	58.57	57.93	58.25
JS-LinearRAG _{pst}	36.00	40.50	38.25	67.50	60.80	<u>64.15</u>	68.30	70.10	69.20	<u>57.27</u>	<u>57.13</u>	<u>57.20</u>

表 4-2 在三个多跳问答数据集上的性能对比, 基座模型为 Llama-3-8B-Instruct

Method	MuSiQue			2WikiMultiHopQA			HotpotQA			Average		
	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg
TTRAG _{sk+docs}	<u>22.30</u>	<u>28.50</u>	<u>25.40</u>	58.50	47.40	<u>52.95</u>	63.90	<u>59.80</u>	61.85	<u>48.23</u>	<u>45.23</u>	<u>46.73</u>
TTRAG _{sk+sens}	23.60	29.90	26.75	<u>58.40</u>	49.00	53.70	63.80	60.30	<u>62.05</u>	48.60	46.40	47.50
TTRAG _{sk+docs+se}	21.20	27.20	24.20	51.30	42.20	46.75	65.10	<u>59.80</u>	62.45	45.87	43.07	44.47
TTRAG _{sk+sens+se}	21.50	28.00	24.75	54.10	44.90	49.50	<u>63.90</u>	58.20	61.05	46.50	43.70	45.10
JS-LinearRAG	21.80	18.60	20.20	54.70	35.00	44.85	59.10	50.20	54.65	45.20	34.60	39.90
JS-LinearRAG _{pst}	22.10	18.30	20.20	55.10	35.40	45.25	59.30	51.90	55.60	45.50	35.20	40.35

(1) 整体性能分析。从整体实验结果来看, JS-LinearRAG 在 GPT-4o-mini 设置下取得了最优的综合性能, 平均 Contain-Acc.、GPT-Acc. 与整体 Avg 分别达到 58.57%、57.93% 和 58.25%, 在所有方法中排名第一。

相比 Dense Retrieval、LightRAG、HippoRAG、GFM-RAG 与 HippoRAG2 等主流方法, JS-LinearRAG 均表现出显著优势。例如, 相比当前较强基线 HippoRAG2, JS-LinearRAG 在平均 Contain-Acc. 上提升约 6.37 个百分点, 在整体 Avg 上提升约 6.43 个百分点; 相比 LinearRAG, 平均 Contain-Acc.、GPT-Acc. 与整体 Avg 分别提升约 2.47、2.60 和 2.53 个百分点。这一结果表明, 通过结构与语义联合建模, 即使不依赖复杂的显式知识图谱推理路径, 仍能够有效提升大语言模型在复杂多跳问答任务中的检索质量、语义表达能力与推理性能。相比于传统基于图结构的 RAG 方法主要依赖复杂关系建模与显式路径搜索, JS-LinearRAG 更加强调通过联合语义信息提升知识密度与上下文表达效率, 从而在保证性能的同时降低结构构建成本, 体现出更强的轻量化优势。

与 LinearRAG 相比, JS-LinearRAG 的平均 Contain-Acc. 从 56.10% 提升至 58.57%, GPT-Acc. 从 55.33% 提升至 57.93%, 整体 Avg 从 55.72% 提升至 58.25%。该结果充分验证了本文提出的联合语义信息抽取、句子加权表示以及结构增强联合语义上下文构建方法的整体有效性。通过引入实体语义单元丰富语义信息, 结合句子级语义建模优化段落表示, 模型能够更加全面地表达复杂语义关系, 从而显著提升检索质量与生成效果。尤其是在 MuSiQue 数据集上, JS-LinearRAG 的 Avg 达到 37.75%, 相较原始 LinearRAG 提升约 4.55 个百分点; 进一步引入短语结构三元组结构增强后的 JS-LinearRAG_{pst} 更提升至 38.25%, 表明在推理路径更长、问题结构更复杂的任务场景中, 适度引入结构信息能够增强结构分析能力。这说明联合语义建模在复杂推理任务中具有较强优势, 而结构增强机制则可在部分高复杂度任务中提供额外补充。

(2) 结构与语义融合分析。进一步观察结构增强的 JS-LinearRAG_{pst}。

在较小规模模型 Llama-3-8B-Instruct 条件下, JS-LinearRAG_{pst} 相较于原始 JS-LinearRAG 在三个数据集及整体平均性能上均实现稳定提升。例如, 其整体 Avg 由 39.90% 提升至 40.35%, 在 2WikiMultiHopQA 上由 44.85% 提升至 45.25%, 在 HotpotQA 上由 54.65% 提升至 55.60%。这一现象说明, 当模型自身参数规模较小、隐式推理能力有限时, 短语结构三元组结构增强能够为联合语义框架提供更加明确的外部结构约束, 有效补偿弱模型在复杂结构推理方面的不足。换言之, 结构增强对于弱模型条件下的 JS-LinearRAG 不仅是局部补充, 更在一定程度上提升了整体推理稳定性与泛化能力。

在 GPT-4o-mini 条件下, 其在数据集 MuSiQue 上取得最高 Avg (38.25%), 并在 MuSiQue 的 C-Acc. 指标上达到最优, 说明在联合语义建模框架中适度引入短语结构三元组结构信息, 能够增强复杂多跳任务中的结构组织能力与知识覆盖范围。尤其是在 MuSiQue 这类问题复杂度更高、需要更强推理深度的数据集上, 短语结构三元组结构增强有助于补充原有隐式语义推理在结构约束方面的不足, 从而提升模型对复杂推理路径的捕捉能力。然而, JS-LinearRAG_{pst} 在 2WikiMultiHopQA 数据集上的性能有所下降, 整体 Avg 由 67.00% 降至 64.15%, 导致其总体平均性能 (57.20%) 略低于原始 JS-LinearRAG (58.25%)。这一结果说明, 对于以联合语义建模为核心的隐式推理框架而言, 随着模型自身语义整合能力增强, 短语结构三元组结构信息更适合作为辅助增强信号, 用于在高复杂度任务中补充结构分析能力, 而不宜过度强化其结构主导作用; 否则可能因引入额外结构约束与局部噪声, 削弱原有联合语义建模在轻量化、高灵活性方面的优势。因此, JS-LinearRAG 的结构增强效果具有明显的模型规模依赖性: 在弱模型条件下, 结构增强能够有

效补偿推理能力不足；而在强模型条件下，过强结构增强反而可能影响语义建模效率。

对于第三章提出的 TTRAG 方法,实验结果显示,在原有显式短语结构三元组结构分析框架中引入联合语义增强后, $TTRAG_{sk+docs+se}$ 与 $TTRAG_{sk+sens+se}$ 并未稳定优于原始 TTRAG, 部分数据集甚至出现不同程度下降。例如, 在 GPT-4o-mini 设置下, $TTRAG_{sk+docs}$ 的整体 Avg 为 56.92%, 而 $TTRAG_{sk+docs+se}$ 降至 55.43%; $TTRAG_{sk+sens}$ 的整体 Avg 为 55.95%, 而 $TTRAG_{sk+sens+se}$ 降至 54.43%。这一现象表明, 对于以显式结构分析为核心的推理框架而言, 原有短语结构三元组推理路径已经较好完成了证据筛选、结构组织与上下文压缩任务, 其核心优势在于结构纯净性与高信噪比。额外引入过多语义增强信息可能打破原有结构路径的纯净性与推理连贯性, 增加冗余语义干扰, 从而影响整体推理效率与结构优势。

但值得注意的是, 在 HotpotQA 数据集上, 无论是 Llama-3-8B-Instruct 还是 GPT-4o-mini 设置下, TTRAG 的语义增强变体 ($TTRAG_{sk+docs+se}$) 在 C-Acc. 与 Avg 指标上均取得了最优表现, 例如在 GPT-4o-mini 设置下, $TTRAG_{sk+docs+se}$ 的 C-Acc. 达到 72.10%, Avg 达到 71.30%, 均优于原始 TTRAG。这一结果说明在部分需要丰富文本语义补充的任务中, 语义增强仍可以为显式结构框架带来局部收益。因此, 对于 TTRAG 而言, 语义增强并非没有效果, 而是需要更加谨慎地控制其融合强度与方式。

综合来看, 上述实验结果说明结构信息与语义信息并非简单替代关系, 而是在不同方法范式及不同模型规模条件下呈现出差异化的互补机制: 对于显式结构化推理方法 (TTRAG), 结构分析为主体, 语义增强应保持适度, 以避免影响整体的推理效率与结构优势; 对于隐式联合语义推理方法 (JS-LinearRAG), 语义分析为主体, 结构增强可作为辅助补充, 用于提升复杂任务中的结构组织能力。

(3) **模型规模分析。**在不同参数规模的大语言模型条件下, 本文方法呈现出明显的模型适应性差异。

在较小规模模型 Llama-3-8B-Instruct 条件下, TTRAG 系列方法整体表现显著优于 JS-LinearRAG 系列方法。其中, $TTRAG_{sk+sens}$ 的整体 Avg 达到 47.50%, $TTRAG_{sk+docs}$ 达到 46.73%, 而 JS-LinearRAG 仅为 39.90%, 即使引入短语结构三元组结构增强后的 JS-LinearRAG_{pst} 也仅提升至 40.35%。这一结果说明, 当回答模型自身参数规模较小、隐式推理能力较弱时, 显式短语结构三元组结构分析的重要性进一步提升。而在 GPT-4o-mini 条件下, JS-LinearRAG 则取得整体最佳性能, 整体 Avg 达到 58.25%, 显著优于 TTRAG 系列方法。这一结果说明, 随着模型规模与语义理解能力增强, 联合语义建模的优势能够得到更充分释放。较强模型能够

更有效整合实体、短语结构三元组及文本段落信息，从而在无需复杂显式推理路径的情况下实现更高效的推理过程。

TTRAG 所构建的结构化推理路径能够为中小规模模型提供更加明确的推理步骤、知识筛选机制与结构组织框架，有效降低复杂多跳推理任务对模型自身隐式推理能力的依赖。通过外部结构路径补偿模型参数能力不足，TTRAG 能够在较弱模型条件下维持相对稳定的推理表现。相比之下，JS-LinearRAG 虽然通过结构与语义联合建模提升知识密度与上下文表达能力，但其核心仍依赖模型自身对联合语义信息进行隐式整合与推理。因此，当模型规模较小时，其联合语义优势难以充分转化为稳定的推理性能，导致整体表现明显弱于显式结构化推理方法。

从方法适用性角度来看，该结果验证了两种方法在不同模型规模下的差异化优势：对于中小规模模型，TTRAG 的显式结构分析机制更具稳定性与适应性，能够通过外部结构路径有效补偿模型自身推理能力不足；对于较大规模或语义理解能力更强的模型，JS-LinearRAG 更适合以较低结构成本实现高效推理，体现出更好的效率与性能。

(4) 检索规模分析。两种方法在初始实验中采用不同的检索规模，TTRAG 采用基于检索文档构建小规模图的 RAG 方法中通常设置的检索规模 $\text{top-}k = 10$ ，而 JS-LinearRAG 采用多数 RAG 基线方法通常设置的检索规模 $\text{top-}k = 5$ 。这一差异并非简单的实验参数选择，而是由两种方法在上下文组织机制上的本质区别决定。

具体而言，TTRAG 通过短语结构三元组结构分析对候选文档进行结构化筛选、路径约束与上下文压缩，能够显著降低最终输入大语言模型的上下文长度，因此可在保持提示词规模可控的前提下使用更大的检索范围 ($\text{top-}k = 10$)，以尽可能覆盖潜在多跳推理所需的更多候选证据。相比之下，JS-LinearRAG 虽然通过结构与语义联合建模提升信息密度，但其最终上下文仍保留一定数量的原始段落内容。当检索规模继续扩大时，额外段落可能带来更多冗余信息与上下文噪声，从而削弱其轻量化结构分析优势。因此，JS-LinearRAG 更适合采用较小的检索规模 ($\text{top-}k = 5$)，以在性能、上下文长度与计算成本之间取得更优平衡。

从实验结果来看，在 $\text{top-}k = 5$ 设置下，JS-LinearRAG 在整体平均性能上取得最优表现，整体 Avg 达到 58.25%，优于同设置下多种基线方法及 TTRAG。TTRAG_{sk+docs} 与 TTRAG_{sk+sens} 在 HotpotQA 数据集上仍表现出较强性能，但在整体平均性能上低于 JS-LinearRAG。这表明，在较小检索规模下，JS-LinearRAG 通过构建“结构 + 文本 + 语义”联合增强上下文，能够在较低上下文成本下获得较高的信息密度与更稳定的整体性能。

在统一 $\text{top-}k = 10$ 设置下的对比实验结果如表 4-3 所示。在较大检索规模条件下，TTRAG 的结构化推理优势得到充分体现：TTRAG_{sk+docs} 的整体 Avg 达到

58.57%， $TTRAG_{sk+sens}$ 达到 57.73%，均优于 JS-LinearRAG 在 $top-k = 10$ 下的整体 Avg (57.12%)。结果说明，当候选文档规模扩大时，TTRAG 能够通过显式短语结构三元组推理路径有效组织和筛选额外文档中的潜在推理信息，从而更充分地利用高召回检索带来的优势。结构化推理路径在大规模候选文档条件下能够显著提升额外信息利用效率，避免因额外段落引入过多冗余信息而导致性能下降。

表 4-3 JS-LinearRAG 与 TTRAG 在 $top-k = 10$ 检索设置下的性能对比

Method	MuSiQue			2WikiMultiHopQA			HotpotQA			Average		
	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg
$TTRAG_{sk+docs}$	<u>31.50</u>	44.00	37.75	<u>69.30</u>	<u>61.00</u>	65.15	<u>73.30</u>	<u>72.30</u>	<u>72.80</u>	58.03	59.10	58.57
$TTRAG_{sk+sens}$	30.20	42.90	<u>36.55</u>	67.50	59.80	63.65	73.60	72.40	73.00	57.10	<u>58.37</u>	<u>57.73</u>
JS-LinearRAG	34.20	38.20	36.20	69.90	63.40	66.65	68.00	69.00	68.50	<u>57.37</u>	56.87	57.12

相比之下，JS-LinearRAG 在 $top-k = 10$ 设置下整体 Avg 低于 TTRAG，表明当候选文档数量增加时，若缺乏显式推理路径的结构引导，难以消除额外文本引入的冗余信息与上下文噪声带来的影响。但其在 2WikiMultiHopQA 数据集上取得最高 Avg (66.65%)，说明联合语义联合建模在部分多跳任务上具有明显优势，尤其在语义关联更强、结构复杂度相对适中的任务中，隐式联合语义推理仍可保持较高性能。

综合来看，JS-LinearRAG 的优势更集中体现在较低检索规模下的高效语义组织，而 TTRAG 的优势更集中体现在较大检索规模下的结构化证据筛选。检索规模分析说明：TTRAG 更适合高召回、大检索规模场景，通过显式结构分析充分利用更多候选证据，适用于复杂多跳推理任务；JS-LinearRAG 更适合低成本、小检索规模场景，通过联合语义建模实现高知识密度推理，适用于高效率任务。

4.5.5 消融实验结果及分析

为验证本文各模块设计的有效性，本文逐步引入不同组件，构建多组对比实验，结果如表 4-4 所示。消融实验主要围绕三方面展开：联合语义信息抽取、句子加权表示以及联合语义上下文构建。为便于描述不同模块组合，本文采用如下命名方式：ent 表示实体 (entity)，sw 表示句子加权表示 (sentence-weighted embedding)，js 表示联合语义上下文 (joint semantic context)，pst 表示短语结构三元组 (phrase-structured triples)。其中，pst 表示由开放式信息抽取获得的短语结构三元组结构信息，作为联合语义建模中的辅助结构增强模块。

(1) 联合语义信息抽取的有效性：首先，对比 $LinearRAG_{ent}$ 、 $LinearRAG_{pst}$ 与 $LinearRAG_{ent+pst}$ 三种设置可以观察到，相比仅使用单一实体或短语结构三元组，联合短语结构三元组与实体语义信息后整体性能呈现稳定提升趋势。其中， $LinearRAG_{ent+pst}$ 的整体平均性能由 $LinearRAG_{ent}$ 的 55.72% 提升至 56.55%，平均提升

表 4-4 JS-LinearRAG 各模块消融实验结果

Method	MuSiQue			2WikiMultiHopQA			HotpotQA			Average		
	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg	C-Acc.	G-Acc.	Avg
LinearRAG _{ent}	31.50	34.90	33.20	69.80	64.20	67.00	67.00	66.90	66.95	56.10	55.33	55.72
LinearRAG _{pst}	31.80	35.40	33.60	68.80	61.70	65.25	66.60	67.40	67.00	55.73	54.83	55.28
LinearRAG _{ent+pst}	32.90	36.90	34.90	68.20	66.20	67.20	66.60	68.50	67.55	55.90	57.20	56.55
LinearRAG _{ent+sw}	33.90	38.90	36.40	69.90	64.60	<u>67.25</u>	66.40	67.30	66.85	56.73	56.93	56.83
LinearRAG _{ent+js}	33.80	38.90	36.35	71.70	<u>65.40</u>	68.55	66.10	68.40	67.25	57.20	57.57	57.38
LinearRAG _{ent+pst+js}	<u>35.30</u>	39.30	37.30	<u>70.10</u>	64.10	67.10	68.00	70.60	<u>69.30</u>	<u>57.80</u>	58.00	<u>57.90</u>
JS-LinearRAG	35.20	<u>40.30</u>	<u>37.75</u>	70.00	64.00	67.00	70.50	69.50	70.00	58.57	<u>57.93</u>	58.25
JS-LinearRAG _{pst}	36.00	40.50	38.25	67.50	60.80	64.15	<u>68.30</u>	<u>70.10</u>	69.20	57.25	57.13	57.20

约 0.83 个百分点。在 MuSiQue 数据集上, Avg 指标由 33.20% 提升至 34.90%; 在 HotpotQA 上, Avg 指标由 66.95% 提升至 67.55%; 同时在 2WikiMultiHopQA 上, GPT-Acc. 达到 66.20%, 达到最佳结果。结果表明, 相比仅依赖实体级语义信息或仅依赖于短语结构三元组信息, 联合短语结构三元组与实体语义信息能够有效补充更加完整的概念性和描述性语义表达, 增强语义覆盖范围, 从而提升检索质量与答案生成能力。因此, 第 4.2 节提出的联合语义信息抽取机制能够为后续检索增强生成提供更加丰富的语义基础。

(2) 句子加权表示的影响: 在语义信息抽取基础上, 进一步引入句子加权段落表示后, 模型性能继续提升。LinearRAG_{ent+sw} 的整体平均性能达到 56.83%, 相比原始 LinearRAG_{ent} 提升约 1.11 个百分点。其中, MuSiQue 数据集上的 Avg 指标由 33.20% 提升至 36.40%, 提升最为显著。这一结果说明, 相较于直接对段落整体编码, 基于句子重要性加权的表示方式能够更精细地建模段落内部语义结构, 突出关键句子信息, 减少冗余内容干扰, 从而提升段落表示质量。这验证了第 4.3 节提出的句子加权表示方法在语义表示精度方面的有效性。

(3) 联合语义上下文构建的作用: 进一步引入联合语义上下文构建后, 模型整体性能获得持续提升。LinearRAG_{ent+js} 在 2WikiMultiHopQA 数据集上取得 68.55% 的最高 Avg 指标, 说明仅通过联合语义上下文组织, 即使不引入知识结构三元组, 也能够显著增强信息组织能力。当进一步结合完整语义信息抽取后, LinearRAG_{ent+pst+js} 的整体平均性能达到 57.90%, 较基础 LinearRAG_{ent} 提升约 2.18 个百分点。其中: MuSiQue Avg 达到 37.30%, HotpotQA Avg 达到 69.30%, 整体 Contain-Acc. 与 GPT-Acc. 分别达到 57.80% 和 58.00%。这一结果表明, 联合语义信息抽取与联合上下文构建之间存在明显协同作用, 通过将短语结构三元组、段落、实体语义信息进行层级化组织, 能够有效提升上下文知识密度与模型推理能力。在此基础上, 进一步引入句子加权表示, 即 JS-LinearRAG, 整体 Avg 达到 58.25%。尤其在 HotpotQA 上, Contain-Acc. 达到 70.50%, 整体 Avg 达到 70.00%, 表现最优。这一结果表明, 句子级表示优化与联合语义上下文构建能够形成更强的互补作用, 共同提升复杂多跳问答任务中的检索与推理表现。

(4) 短语结构三元组结构增强的影响: 进一步分析结构增强的 JS-LinearRAG_{pst} 模型在部分高复杂度任务上展现出进一步提升。JS-LinearRAG_{pst} 在 MuSiQue 数据集上取得最高 Avg (38.25%), 同时在 MuSiQue 的 C-Acc. (36.00%)、G-Acc. (40.50%) 上均达到最佳表现。结果表明, 在推理路径更长、结构复杂度更高的任务场景中, 适度引入短语结构三元组结构增强能够进一步补充联合语义建模在结构组织能力上的不足, 增强模型对复杂推理路径的捕捉能力。短语结构三元组结构增强通过引入更明确的实体关系约束, 使模型在联合语义表示基础上进一步获得局部结构信息支持, 从而在复杂问题中实现更高质量的知识组织。这说明, 在以语义分析为主体的框架中, 结构分析作为辅助增强机制能够有效提升模型在高复杂度任务中的推理能力。

4.5.6 样例分析

为分析所提出方法在实际多跳推理任务中的表现, 本文选取一个典型案例进行对比分析。待回答的问题为: “Which film has the director who was born later, *Playing It Wild* or *I’ll Be Going Now*?”

如图 4-3 所示, 左侧为 LinearRAG 的检索结果, 右侧为本文提出的 JS-LinearRAG 的检索结果。可以观察到, LinearRAG 在前 $k = 5$ 个检索文档中未能返回与问题直接相关的关键信息, 导致后续模型缺乏有效证据支撑, 难以完成正确推理。这一现象表明, 当仅依赖实体级语义并采用统一的整体段落嵌入表示进行检索时, 模型难以刻画段落内部的语义差异, 容易受到表面语义匹配的干扰, 从而遗漏关键的推理路径信息。

相比之下, JS-LinearRAG 能够准确检索到与问题相关的核心实体与语义信息。具体而言, 模型成功定位到两个目标电影 “Playing It Wild” 和 “I’ll Be Going Now”, 并进一步检索到其对应导演分别为 “William Duncan” 和 “Dino Risi”。在此基础上, 模型继续获取两位导演的出生日期信息, 其中 “William Duncan” 出生于 1879 年 12 月 16 日, 而 “Dino Risi” 出生于 1916 年 12 月 23 日。通过对两者出生时间的比较, 可以正确推断出 “I’ll Be Going Now” 的导演出生更晚, 从而得到正确答案。

进一步分析 JS-LinearRAG 的优势来源, 可以发现其不仅受益于联合语义建模与联合语义上下文构建, 还得益于基于句子加权的段落表示方法。相比于传统的整体段落编码方式, 该方法通过对段落中各句子的嵌入进行加权聚合 (以句子长度为权重), 能够更准确地刻画段落内部的语义分布, 使包含关键事实信息的句子在表示中占据更大权重。在本案例中, 与导演及其出生时间相关的句子通常信息

密度较高且长度较长，因此在加权表示中被显著强化，从而提升了相关段落检索阶段的排序位置。

这一机制有效缓解了传统方法中“关键信息被淹没于冗余文本”的问题，使模型能够更加稳定地捕捉跨文档的关键语义线索，并支持多跳推理过程中的信息衔接。相比之下，LinearRAG 采用统一的段落表示方式，难以区分段落内部不同句子的语义重要性，从而在复杂查询下更容易出现检索偏差。




图 4-3 LinearRAG 与 JS-LinearRAG 的文档检索结果样例

4.6 本章小结

本章针对基于图结构的 RAG 方法依赖复杂关系建模且构建成本较高的问题，提出了一种基于结构与语义联合建模的检索增强生成方法（JS-LinearRAG）。该方法在短语结构三元组和文本片段的基础上，围绕“结构 + 文本 + 语义”联合增强的核心思想进行了系统性改进。首先在语义信息抽取阶段，联合短语结构三元组抽取与实体语义信息抽取，在增强语义覆盖能力的同时补充结构关系信息；其次，在表示学习阶段提出基于句子加权的段落表示方法，通过建模句子级语义分布，提高段落表示的精细程度；最后，在上下文构建阶段提出结构增强的联合语义上下文构建方法，构建“结构 + 文本 + 语义”的联合增强上下文表示，从而提升上下文的信息密度与表达能力。实验结果表明，所提出方法在多个多跳问答数据集上均取得了优于现有方法的性能表现。消融实验进一步验证了各模块设计的有效性，说明结构与语义联合建模能够有效提升检索质量与复杂推理能力。

结 论

大语言模型在面对需要最新信息或精确知识的任务时，由于蕴含在模型参数中的知识的静态性，容易产生过时或错误的回答。检索增强生成通过引入外部知识，在一定程度上提升了生成结果的事实性与可靠性，但现有 RAG 方法在知识密集型多跳推理任务等复杂场景下仍存在上下文噪声较大、语义表达能力不足以及推理能力有限等问题。针对上述问题，本文围绕“结构分析”与“语义分析”两个关键方向展开研究，分别提出了基于结构分析的检索增强生成方法以及基于结构与语义联合建模的检索增强生成方法，以提升在多跳推理任务中的知识利用效率、上下文表达能力与推理性能。本文的主要贡献包括：

(1) 针对复杂多跳问答任务中上下文信噪比较低的问题，本文提出了一种基于结构分析的检索增强生成方法。本方法首先从检索文档中抽取短语结构三元组，并通过迭代式路径扩展构建结构化推理路径；在此基础上，基于推理路径对原始文本进行精确索引，获取与推理路径一致的文本证据，从而构建“结构引导 + 文本补充”的上下文表示方式。实验结果表明，本方法不仅在各项评价指标上优于对比方法，还能够在保证性能的前提下显著减少输入 Token 长度，有效降低上下文噪声并提升推理效率与结果可解释性。

(2) 针对基于图结构的 RAG 方法依赖复杂关系建模且构建成本较高的问题，本文提出了一种基于结构与语义联合建模的检索增强生成方法。本方法在短语结构三元组和文本片段的基础上，在语义抽取阶段，引入实体语义信息抽取，以增强语义覆盖能力；在表示学习阶段，提出基于句子加权的段落表示方法，更精细地刻画段落内部语义结构；在上下文构建阶段，提出结构增强的联合语义上下文构建方法，构建“结构 + 文本 + 语义”的联合增强上下文表示，提升上下文的信息密度与表达能力。实验结果表明，本方法在无需显式构建完整推理路径的情况下，能够实现更稳定且更优的性能表现，在整体指标上优于多种基准方法。

尽管本文针对多跳问答任务中的检索增强生成方法进行了较为系统的研究，并取得了一定的成果，但仍存在一些不足与值得进一步探索的方向：

(1) 当前结构分析与语义分析两类方法尚未实现深度融合，未来可研究轻量化结构推理与结构语义联合建模的统一框架，以进一步提升模型性能。

(2) 当前语义表示主要依赖静态嵌入模型，对于语义重要性的建模仍较为粗粒度，未来可引入可训练表示学习方法实现更精细的联合语义建模。

(3) 当前上下文构建策略较为固定，未来可探索基于问题复杂度、推理需求或任务场景的动态上下文构建机制，以进一步提升系统的灵活性与效率。

参考文献

- [1] 车万翔, 窦志成, 冯岩松, 等. 大模型时代的自然语言处理: 挑战、机遇与发展[J]. 中国科学: 信息科学, 2023, 53(09): 1645-1687.
- [2] BROWN T, MANN B, RYDER N, et al. Language Models are Few-shot Learners [C] // Proceedings of the 34th Annual Conference on Neural Information Processing Systems : Vol 33, 2020 : 1877-1901.
- [3] OUYANG L, WU J, JIANG X, et al. Training Language Models to Follow Instructions with Human Feedback [C] // Proceedings of the 36th Annual Conference on Neural Information Processing Systems : Vol 35, 2022 : 27730-27744.
- [4] TOUVRON H, LAVRIL T, IZACARD G, et al. Llama: Open and Efficient Foundation Language Models [J]. arXiv preprint arXiv:2302.13971, 2023.
- [5] 时振普, 吕潇, 董彦如, 等. 医学领域多模态知识图谱融合技术发展现状研究[J]. 计算机科学与探索, 2025, 19(07): 1729-1746.
- [6] KANDPAL N, DENG H, ROBERTS A, et al. Large Language Models Struggle to Learn Long-tail Knowledge [C] // Proceedings of the 40th International Conference on Machine Learning, 2023 : 15696-15707.
- [7] ZHANG Y, LI Y, CUI L, et al. Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models [J]. Computational Linguistics, 2025 : 1-46.
- [8] 赵月, 何锦雯, 朱申辰, 等. 大语言模型安全现状与挑战[J]. 计算机科学, 2024, 51(01): 68-71.
- [9] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented Generation for Knowledge-intensive NLP Tasks [C] // Proceedings of the 34th Annual Conference on Neural Information Processing Systems : Vol 33, 2020 : 9459-9474.
- [10] GAO Y, XIONG Y, GAO X, et al. Retrieval-augmented Generation for Large Language Models: A Survey [J]. arXiv preprint arXiv:2312.10997, 2023, 2(1).
- [11] IZACARD G, LEWIS P, LOMELI M, et al. Atlas: Few-shot Learning with Retrieval Augmented Language Models [J]. Journal of Machine Learning Research, 2023, 24(251): 1-43.
- [12] YORAN O, WOLFSON T, RAM O, et al. Making Retrieval-augmented Language Models Robust to Irrelevant Context [C] // Proceedings of the 12th International Conference on Learning Representations, 2024.

- [13] SHI F, CHEN X, MISRA K, et al. Large Language Models Can be Easily Distracted by Irrelevant Context [C] // Proceedings of the 40th International Conference on Machine Learning : Vol 202, 2023 : 31210-31227.
- [14] ASAI A, WU Z, WANG Y, et al. Self-rag: Learning to Retrieve, Generate, and Critique through Self-reflection [C] // Proceedings of the 12th International Conference on Learning Representations, 2024.
- [15] BORGEAUD S, MENSCH A, HOFFMANN J, et al. Improving Language Models by Retrieving from Trillions of Tokens [C] // Proceedings of the 39th International Conference on Machine Learning : Vol 162, 2022 : 2206-2240.
- [16] JIANG Z, XU F F, GAO L, et al. Active Retrieval Augmented Generation [C] // Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, 2023 : 7969-7992.
- [17] HAN H, WANG Y, SHOMER H, et al. Retrieval-augmented Generation with Graphs (Graphrag) [J]. arXiv preprint arXiv:2501.00309, 2024.
- [18] ZHANG Q, CHEN S, BEI Y, et al. A Survey of Graph Retrieval-augmented Generation for Customized Large Language Models [J]. arXiv preprint arXiv:2501.13958, 2025.
- [19] JI S, PAN S, CAMBRIA E, et al. A Survey on Knowledge Graphs: Representation, Acquisition, and Applications [J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 33(2): 494-514.
- [20] GUU K, LEE K, TUNG Z, et al. Retrieval Augmented Language Model Pre-training [C] // Proceedings of the 37th International Conference on Machine Learning : Vol 119, 2020 : 3929-3938.
- [21] KARPUKHIN V, OGUZ B, MIN S, et al. Dense Passage Retrieval for Open-domain Question Answering [C] // Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2020 : 6769-6781.
- [22] RAM O, LEVINE Y, DALMEDIGOS I, et al. In-context Retrieval-augmented Language Models [J]. Transactions of the Association for Computational Linguistics, 2023, 11 : 1316-1331.
- [23] MORRIS J H, SOMAN K, AKBAS R E, et al. The Scalable Precision Medicine Open Knowledge Engine (SPOKE): A Massive Knowledge Graph of Biomedical Information [J]. Bioinformatics, 2023, 39(2): btad080.

- [24] BODENREIDER O. The Unified Medical Language System (UMLS): Integrating Biomedical Terminology [J]. *Nucleic Acids Research*, 2004, 32(suppl_1): D267-D270.
- [25] SOMAN K, ROSE P W, MORRIS J H, et al. Biomedical Knowledge Graph-optimized Prompt Generation for Large Language Models [J]. *Bioinformatics*, 2024, 40(9): btae560.
- [26] YANG R, LIU H, MARRESE-TAYLOR E, et al. Kg-rank: Enhancing Large Language Models for Medical QA with Knowledge Graphs and Ranking Techniques. [C] // *Proceedings of the 23rd Workshop on Biomedical Natural Language Processing*, 2024 : 155-166.
- [27] MAVROMATIS C, KARYPIS G. GNN-RAG: Graph Neural Retrieval for Efficient Large Language Model Reasoning on Knowledge Graphs [C] // *Findings of the Association for Computational Linguistics: ACL 2025*, 2025 : 16682-16699.
- [28] HE G, LAN Y, JIANG J, et al. Improving Multi-hop Knowledge Base Question Answering by Learning Intermediate Supervision Signals. [C] // *Proceedings of the 14th ACM International Conference on Web Search and Data Mining*, 2021 : 553-561.
- [29] MAVROMATIS C, KARYPIS G. ReaRev: Adaptive Reasoning for Question Answering over Knowledge Graphs [C] // *Findings of the Association for Computational Linguistics: EMNLP 2022*, 2022 : 2447-2458.
- [30] VRANDEČIĆ D, KRÖTZSCH M. Wikidata: A Free Collaborative Knowledge-base [J]. *Communications of the ACM*, 2014, 57(10): 78-85.
- [31] AUER S, BIZER C, KOBILAROV G, et al. Dbpedia: A Nucleus for A Web of Open Data [C] // *Proceedings of the 6th International Semantic Web Conference : Vol 4825*, 2007 : 722-735.
- [32] FANG J, MENG Z, MACDONALD C. TRACE the Evidence: Constructing Knowledge-grounded Reasoning Chains for Retrieval-augmented Generation. [C] // *Findings of the Association for Computational Linguistics: EMNLP 2024*, 2024 : 8472-8494.
- [33] LI D, YANG S, TAN Z, et al. Dalk: Dynamic Co-augmentation of LLMs and KG to Answer Alzheimer' s Disease Questions with Scientific Literature [C] // *Findings of the Association for Computational Linguistics: EMNLP 2024*, 2024 : 2187-2205.

- [34] LIANG L, BO Z, GUI Z, et al. Kag: Boosting LLMs in Professional Domains via Knowledge Augmented Generation [C] // Proceedings of the Companion Web Conference 2025, 2025 : 334-343.
- [35] EDGE D, TRINH H, CHENG N, et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization [J]. arXiv preprint arXiv:2404.16130, 2024.
- [36] GUO Z, XIA L, YU Y, et al. LightRAG: Simple and Fast Retrieval-Augmented Generation [C] // Findings of the Association for Computational Linguistics: EMNLP 2025, 2025 : 10746-10761.
- [37] HUANG Y, ZHANG S, XIAO X. Ket-rag: A Cost-efficient Multi-granular Indexing Framework for Graph-RAG [C] // Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 2, 2025 : 1003-1012.
- [38] LUO L, ZHAO Z, HAFARI G, et al. GFM-RAG: Graph Foundation Model for Retrieval Augmented Generation [J]. arXiv preprint arXiv:2502.01113, 2025.
- [39] HE X, TIAN Y, SUN Y, et al. G-retriever: Retrieval-augmented Generation for Textual Graph Understanding and Question Answering [C] // Proceedings of the 38th Annual Conference on Neural Information Processing Systems : Vol 37, 2024 : 132876-132907.
- [40] JIMENEZ GUTIERREZ B, SHU Y, GU Y, et al. Hipporag: Neurobiologically Inspired Long-term Memory for Large Language Models [C] // Proceedings of the 38th Annual Conference on Neural Information Processing Systems : Vol 37, 2024 : 59532-59569.
- [41] GUTIÉRREZ B J, SHU Y, QI W, et al. From RAG to Memory: Non-parametric Continual Learning for Large Language Models [C] // Proceedings of the 42nd International Conference on Machine Learning : Vol 267, 2025 : 21497-21515.
- [42] ZHUANG L, CHEN S, XIAO Y, et al. LinearRAG: Linear Graph Retrieval-Augmented Generation on Large-scale Corpora [C] // Proceedings of the 14th International Conference on Learning Representations, 2026.
- [43] SHI W, MIN S, YASUNAGA M, et al. Replug: Retrieval-augmented Black-box Language Models [C] // Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), 2024 : 8371-8384.
- [44] ROBERTSON S, ZARAGOZA H. The Probabilistic Relevance Framework: BM25 and Beyond : Vol 4 [M] : Now Publishers Inc, 2009.

- [45] IZACARD G, GRAVE E. Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering [C] // Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume, 2021 : 874-880.
- [46] DEVLIN J, CHANG M-W, LEE K, et al. Bert: Pre-training of Deep Bidirectional Transformers for Language Understanding [C] // Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, volume 1 (Long and Short Papers), 2019 : 4171-4186.
- [47] REIMERS N, GUREVYCH I. Sentence-bert: Sentence Embeddings Using Siamese Bert Networks. [C] // Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), 2019 : 3982-3992.
- [48] SONG K, TAN X, QIN T, et al. Mpnet: Masked and Permuted Pre-training for Language Understanding [C] // Proceedings of the 34th Annual Conference on Neural Information Processing Systems : Vol 33, 2020 : 16857-16867.
- [49] WANG L, YANG N, HUANG X, et al. Text Embeddings by Weakly-supervised Contrastive Pre-training [J]. arXiv preprint arXiv:2212.03533, 2022.
- [50] JOHNSON J, DOUZE M, JÉGOU H. Billion-scale Similarity Search with GPUs [J]. IEEE Transactions on Big Data, 2019, 7(3): 535-547.
- [51] LAMPLE G, BALLESTEROS M, SUBRAMANIAN S, et al. Neural Architectures for Named Entity Recognition [C] // Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2016 : 260-270.
- [52] ETZIONI O, BANKO M, SODERLAND S, et al. Open Information Extraction from the Web [J]. Communications of the ACM, 2008, 51(12): 68-74.
- [53] SCHMITZ M, SODERLAND S, BART R, et al. Open Language Learning for Information Extraction [C] // Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning, 2012 : 523-534.
- [54] BAHDANAU D, CHO K, BENGIO Y. Neural Machine Translation by Jointly Learning to Align and Translate [C] // Proceedings of the 3rd International Conference on Learning Representations, 2015.

- [55] TRIVEDI H, BALASUBRAMANIAN N, KHOT T, et al. MuSiQue: Multihop Questions via Single-hop Question Composition [J]. Transactions of the Association for Computational Linguistics, 2022, 10 : 539-554.
- [56] HO X, NGUYEN A-K D, SUGAWARA S, et al. Constructing a Multi-hop QA Dataset for Comprehensive Evaluation of Reasoning Steps [C] // Proceedings of the 28th International Conference on Computational Linguistics, 2020 : 6609-6625.
- [57] YANG Z, QI P, ZHANG S, et al. HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering [C] // Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 2018 : 2369-2380.
- [58] SARTHI P, ABDULLAH S, TULI A, et al. Raptor: Recursive Abstractive Processing for Tree-organized Retrieval [C] // Proceedings of the 12th International Conference on Learning Representations, 2024.
- [59] CHEN J, XIAO S, ZHANG P, et al. Bge M3-embedding: Multi-lingual, Multi-functionality, Multi-granularity Text Embeddings through Self-knowledge Distillation [C] // Findings of the Association for Computational Linguistics: ACL 2024, 2024 : 2356-2376.

攻读硕士学位期间取得创新性成果

（一）发表的学术论文

- [1] Zehua Wang, **Shipeng Li**, Buzhou Tang. CP-Search: A Chain Progressive Search Training Framework Incentivizing the Cognitive Behaviors for Searching in LLMs[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2026, 40(40): 33755-33763. (CCF-A 会议)

（二）参与的科研项目

- [1] 儿科疾病复杂循证知识图谱构建研究, 科技创新 2030—“新一代人工智能”重大项目（课题）.
- [2] 中医典籍智能挖掘与古今融合知识体系构建关键技术研究及应用, 国家重大科技项目（子课题）.
- [3] 基于电子病历多粒度语义分析的动态临床辅助决策方法研究, 国家自然科学基金项目.

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于结构与语义分析的大语言模型检索增强生成方法》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行学术研究工作或专业实践工作所取得的成果，且学位论文中除已标注引用文献、资料的部分外不包含他人完成或已发表的成果；对本学位论文的学术研究工作或专业实践工作做出重要贡献的个人和集体，均已在文中以明确方式注明；对使用AI工具的情况均已在文中以明确方式标注。

作者签名：

日期： 年 月 日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；

（2）学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；

（3）研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：

日期： 年 月 日

导师签名：

日期： 年 月 日

致 谢

首先我要感谢我的导师汤步洲教授，感谢他愿意接受我作为他的学生，在我的整个研究生生涯中，为我的研究提供指导，并安排我积极参加项目。

其次我要感谢我的同门王泽华师兄，感谢他为我提供了许多帮助和支持，感谢他为整个课题组带来了蓬勃的生机和活力，让同门之间的合作更加紧密，也让我在研究中得到了更多的支持和鼓励。

此外我要感谢我的同门高世祺、翁晓龙、仇博宇、张钊进、徐兆斌等，感谢他们丰富了我的研究生生涯，感谢他们在学术上的交流和合作，感谢他们在生活上的关心和支持，也让我体会到了同门之间的友谊和温暖。

同时我要感谢我的室友杨潍豪、钟秉辰、任鹏宇和同学李伯昭、王铭、肖力炜、郑翌恺等，从大学到研究生，在整个七年求学生涯中，学习上，一起学习、合作、分享；生活上，一起吃喝、玩乐、畅聊。感谢他们让我的研究生生涯显得不那么枯燥和孤单。我还要感谢我的家人和朋友，感谢他们为我提供的所有帮助与支持。

最后，感谢母校哈尔滨工业大学（深圳）容纳我的这七年求学时光。时光匆匆，七年光阴，不过一瞬。